

2. Contexto y estado del arte

Esta sección constituye el marco referencial indispensable para fundamentar técnica y científicamente la investigación, estableciendo el puente entre los desafíos actuales de la computación distribuida y las soluciones emergentes en inteligencia artificial embebida. Para ello, el contenido se estructura en tres ejes fundamentales: en primer lugar, se describe el Contexto del problema, analizando la evolución necesaria desde el Cloud Computing hacia los paradigmas de Edge Intelligence y TinyML como respuesta a las demandas de la robótica moderna; seguidamente, se desarrolla el Estado del arte, donde se examinan de forma sistemática las arquitecturas dominantes en detección de objetos (detectores de una y dos etapas) y las capacidades de las plataformas hardware de bajo coste como el ESP32-S3; finalmente, se presentan las Conclusiones de la revisión bibliográfica, identificando los vacíos de conocimiento en términos comparativos que justifican la necesidad y originalidad de este estudio.

2.1.Contexto del problema

La última década ha sido testigo de una transformación tecnológica sin precedentes, impulsada fundamentalmente por la proliferación de dispositivos interconectados en el marco del Internet de las Cosas (IoT). Este fenómeno no es una tendencia pasajera, sino un cambio estructural en la forma en que la sociedad interactúa con la tecnología y el entorno físico. Las proyecciones indican una consolidación de este paradigma, estimando que para el año 2030 el ecosistema IoT superará los 26 mil millones de dispositivos activos a nivel global (Jouini et al., 2024). Esta expansión masiva, que abarca desde sensores industriales y dispositivos de consumo hasta vehículos autónomos y robots de servicio, está generando un volumen de datos de una magnitud y velocidad nunca antes vistas.

Tradicionalmente, el procesamiento y análisis de esta ingente cantidad de datos se ha delegado a infraestructuras centralizadas basadas en la nube (Cloud Computing). Este modelo, si bien ha sido un pilar para el desarrollo de la inteligencia artificial (IA) a gran escala, comienza a mostrar limitaciones significativas frente a las demandas del IoT moderno. La transmisión constante de datos desde miles de millones de dispositivos hacia servidores remotos impone una carga insostenible sobre el ancho de banda de las redes, genera cuellos de botella y, de

manera crítica, introduce una latencia considerable. En aplicaciones donde la toma de decisiones debe ser instantánea —como en la robótica autónoma, la automatización industrial o los sistemas de asistencia a la conducción—, el retardo inherente al ciclo de envío-procesamiento-recepción de la nube es inaceptable y puede comprometer tanto la eficiencia como la seguridad (Chougule et al., 2024). A estas limitaciones se suman las crecientes preocupaciones sobre la privacidad y la soberanía de los datos, ya que la información sensible debe viajar fuera del dispositivo local para ser procesada.

Como respuesta directa a estos desafíos, ha surgido un cambio de paradigma computacional desde el Cloud Computing hacia el Edge Computing, o computación en el borde. Como señalan Chougule et al. (2024), este enfoque propone una descentralización del procesamiento, trasladando la capacidad de cómputo lo más cerca posible de la fuente donde se generan los datos. Al procesar la información localmente en el propio dispositivo o en un nodo cercano, el Edge Computing mitiga de forma efectiva los problemas de latencia, reduce drásticamente la dependencia del ancho de banda y refuerza la privacidad al minimizar la transferencia de datos brutos a la nube.

Esta evolución ha sentado las bases para el siguiente paso lógico: la Inteligencia en el Borde (Edge Intelligence). Este concepto va más allá del simple procesamiento de datos y se enfoca en la ejecución de algoritmos de inteligencia artificial, y más concretamente modelos de aprendizaje profundo (Deep Learning), directamente en los dispositivos de borde (Wang et al., 2025). La integración de la IA en el borde está catalizando una nueva generación de aplicaciones inteligentes y autónomas. En el ámbito industrial, por ejemplo, la Edge Intelligence es un habilitador clave de la Industria 4.0 y 5.0, permitiendo el desarrollo de sistemas de mantenimiento predictivo, control de calidad visual en tiempo real y optimización de procesos directamente en la línea de producción. Rahman et al. (2025) destacan en su revisión sobre automatización industrial un "creciente cambio hacia el despliegue en el borde en tiempo real", subrayando la importancia de esta tecnología para la competitividad y eficiencia del sector. El lenguaje de programación Python, gracias a su robusto ecosistema de librerías y herramientas como TensorFlow, PyTorch, Open Neural Network Exchange, Edge y Impulse, se ha consolidado como el estándar de facto para el desarrollo de estas aplicaciones, facilitando la transición de los modelos de IA desde los centros de datos hasta los dispositivos de borde (Thind, 2025).

No obstante, la implementación de la Edge Intelligence presenta un desafío técnico fundamental: la disparidad entre los requerimientos computacionales de los modelos de IA modernos y las capacidades inherentemente limitadas de los dispositivos de borde. Los microcontroladores, procesadores de señal digital (DSP) y sistemas en un chip (SoC) que potencian la mayoría de los dispositivos IoT operan con restricciones severas de memoria (a menudo en el orden de kilobytes o pocos megabytes), capacidad de procesamiento (medida en megahercios, no gigahercios) y, sobre todo, consumo energético (operando en el rango de milivatios) (Ray, 2022). Las redes neuronales profundas (DNN), por su parte, son conocidas por su complejidad, con millones de parámetros que demandan una considerable memoria y potencia de cálculo, un requisito que choca frontalmente con las limitaciones del hardware de borde.

Para superar esta barrera, la comunidad científica y tecnológica ha desarrollado un conjunto de técnicas de optimización y compresión de modelos, cuyo objetivo es reducir drásticamente la huella computacional de las redes neuronales sin sacrificar de manera significativa su precisión. Como describen Wang et al. (2025) y Tang et al. (2023), entre estas técnicas destacan la cuantización, que consiste en reducir la precisión numérica de los pesos del modelo (por ejemplo, de punto flotante de 32 bits a enteros de 8 bits), y la poda (pruning), que elimina conexiones neuronales redundantes. La cuantización por sí sola puede llegar a reducir el tamaño de un modelo hasta en un 75%, un factor clave para su viabilidad en sistemas embebidos.

En este contexto de optimización nace el paradigma conocido como Tiny Machine Learning o TinyML. Lejos de ser un simple subconjunto del Edge AI, TinyML es un campo de estudio y aplicación altamente especializado que se enfoca en la intersección de algoritmos de aprendizaje automático, hardware de ultra-bajo consumo y software embebido (Ray, 2022). El objetivo de TinyML es hacer posible la ejecución de modelos de inferencia directamente en microcontroladores de bajo coste, abriendo la puerta a la inteligencia artificial en miles de millones de dispositivos que anteriormente eran incapaces de soportarla. Según Pazmiño Ortiz et al. (2025), TinyML representa el nivel más profundo de la computación en el borde, donde la autonomía, la eficiencia energética y el bajo coste son los pilares fundamentales.

El ecosistema TinyML ha madurado rápidamente, ofreciendo un conjunto de herramientas estandarizadas que facilitan el flujo de trabajo desde el entrenamiento del modelo hasta su

despliegue. Frameworks como TensorFlow Lite, específicamente su versión para microcontroladores, se han vuelto indispensables para convertir modelos entrenados en formatos compactos y eficientes (Kallimani et al., 2024). A nivel de hardware, una variedad de plataformas se ha popularizado para el desarrollo de aplicaciones TinyML, entre las que destacan placas como la serie Arduino, Raspberry Pi y, de manera notable, microcontroladores como la familia ESP32, reconocida por su equilibrio entre coste, conectividad y capacidad de procesamiento (Kallimani et al., 2024; Schizas et al., 2022).

Un dominio de aplicación donde el paradigma TinyML está generando un impacto particularmente transformador es en la robótica, y más específicamente, en el campo de la visión por computador embebida (Embedded Vision). La capacidad de percibir y comprender el entorno visual es un requisito indispensable para cualquier robot autónomo. Como señala la revisión de Li et al. (2025), la inteligencia artificial está redefiniendo la robótica moderna, especialmente en las áreas de percepción y toma de decisiones. Los sistemas de visión embebidos, que integran sensores de imagen y unidades de procesamiento en una única plataforma compacta, son el "sentido de la vista" de estos robots (Bhowmik & Appiah, 2018).

La convergencia de TinyML y la visión embebida está permitiendo el desarrollo de robots móviles que pueden realizar tareas de detección, clasificación y seguimiento de objetos de forma autónoma, sin depender de una conexión a la nube o de costosas unidades de procesamiento externas. Beltrán-Escobar et al. (2024) argumentan en su revisión que los sistemas embebidos de bajo coste y recursos limitados son, de hecho, superiores para muchas aplicaciones de robótica móvil, y destacan específicamente a TinyML como la tecnología habilitadora para la visión inteligente en estas plataformas. Este enfoque no solo democratiza el acceso a la robótica inteligente, sino que también abre nuevas posibilidades en sectores como la logística, la agricultura de precisión y, de manera muy significativa, la educación.

El imperativo del "bajo coste" es un factor transversal en este contexto. Para que la robótica avanzada y la IA puedan ser herramientas de aprendizaje efectivas y accesibles, es crucial desarrollar plataformas que utilicen componentes asequibles y de fácil acceso. La investigación actual valida activamente este enfoque. Por ejemplo, el trabajo de Kassem y Asem (2024) demuestra la viabilidad de construir un sistema de localización y mapeo simultáneo (SLAM) utilizando una Raspberry Pi y una cámara de bajo coste, en lugar de sensores LiDAR, que son órdenes de magnitud más caros. De manera similar, se han

Guía metodológica para la implementación de sistemas de detección de objetos en microcontroladores ESP32-S3: Un enfoque basado en TinyML y arquitecturas Deep Learning desarrollado aplicaciones prácticas de visión embebida en hardware de bajo coste para dominios tan diversos como la asistencia a personas con discapacidad visual (Hashmi et al., 2021) o la detección de objetos por color en microcontroladores STM32 (Ayala et al., 2022).

2.2.Estado del arte

La implementación de sistemas de percepción visual en robots móviles de bajo coste constituye un campo de investigación activo y multidisciplinar, que interseca la robótica, la visión por computador y la inteligencia artificial embebida. La capacidad de un agente autónomo para detectar e identificar objetos en su entorno es fundamental para la ejecución de tareas de navegación, manipulación e interacción. Históricamente, esta capacidad ha estado reservada a plataformas robóticas con un considerable poder computacional. Sin embargo, la evolución reciente en el hardware de microcontroladores y el desarrollo de nuevos paradigmas de software, como Tiny Machine Learning (TinyML), están democratizando el acceso a estas tecnologías.

Esta sección presenta una revisión sistemática de la literatura científica para contextualizar la presente investigación, analizando desde los paradigmas dominantes en la detección de objetos hasta las soluciones específicas implementadas en hardware con recursos computacionales limitados. El objetivo es delimitar el estado actual de conocimiento y la base de este Trabajo de Fin de Máster que se propone abordar.

2.2.1. Paradigmas Dominantes en la Detección de Objetos

La detección de objetos como disciplina dentro de la visión por computador ha experimentado una transformación radical con la llegada de las Redes Neuronales Convolucionales (CNN). Estos modelos de aprendizaje profundo han desplazado progresivamente a los enfoques clásicos basados en características manuales (e.g., SIFT, SURF), estableciendo nuevos récords de precisión en benchmarks estandarizados como COCO (Common Objects in Context) y Pascal VOC (Visual Object Classes). La literatura actual se encuentra dominada por dos grandes familias de arquitecturas: los detectores de dos etapas y los detectores de una etapa.

Los detectores de dos etapas, cuya familia más representativa es R-CNN (Region-based Convolutional Neural Network) y sus sucesivas evoluciones como Fast R-CNN y Faster R-CNN, se caracterizan por un enfoque secuencial (Girshick et al., 2014). Primero, un algoritmo de propuestas de región genera una serie de áreas de interés (bounding boxes) donde es probable que se encuentre un objeto. Posteriormente, una CNN clasifica cada una de estas propuestas. Si bien este método alcanza elevados niveles de precisión, su naturaleza

secuencial impone una carga computacional significativa, resultando en una baja velocidad de inferencia que lo hace inviable para aplicaciones en tiempo real sobre hardware limitado (Zhao et al., 2019).

En contraposición, los detectores de una etapa abordan la detección como un problema de regresión directa. Arquitecturas como SSD (Single Shot MultiBox Detector) y, de manera muy destacada, la familia de modelos YOLO (You Only Look Once), procesan la imagen en una única pasada para predecir simultáneamente las coordenadas de las cajas delimitadoras y las probabilidades de clase asociadas (Redmon et al., 2016). Este enfoque unificado reduce drásticamente el tiempo de inferencia, posicionando a los modelos YOLO como el estándar de facto para aplicaciones que demandan un equilibrio entre velocidad y precisión, como la conducción autónoma o la robótica industrial (Barodi et al., 2025; Okano et al., 2025). Versiones más recientes, como YOLOv8, continúan refinando esta arquitectura para mejorar la eficiencia y la flexibilidad, consolidando su dominio en el campo (Ahmad et al., 2025). El éxito de estas arquitecturas, sin embargo, se sustenta en el uso de Unidades de Procesamiento Gráfico (GPU) de alto rendimiento, un recurso inexistente en el dominio de la robótica de bajo coste que se aborda en este trabajo.

2.2.2. La Transición al Borde: Edge AI y el Paradigma TinyML

La dependencia de la computación en la nube o de hardware de alto rendimiento para ejecutar modelos de aprendizaje profundo presenta barreras significativas para su despliegue masivo en el Internet de las Cosas (IoT) y la robótica. Como señalan Wang et al. (2025), factores como la latencia de la red, el consumo de ancho de banda, los costes operativos y las consideraciones de privacidad de los datos han impulsado la transición hacia el procesamiento en el borde (Edge AI). Este paradigma aboga por ejecutar las inferencias de los modelos de IA directamente en el dispositivo donde se capturan los datos.

Dentro del ecosistema de Edge AI, ha surgido con fuerza el subcampo de Tiny Machine Learning (TinyML), enfocado específicamente en el despliegue de modelos de aprendizaje automático en microcontroladores (MCU) y otros dispositivos con restricciones severas de memoria, cómputo y energía (Wardhana et al., 2024). Los MCU, como los de la familia ESP32, operan típicamente con kilobytes de memoria RAM y velocidades de reloj del orden de

Guía metodológica para la implementación de sistemas de detección de objetos en microcontroladores ESP32-S3: Un enfoque basado en TinyML y arquitecturas Deep Learning megahercios, un entorno computacional órdenes de magnitud más limitado que el de un smartphone o una GPU.

La viabilidad de TinyML se fundamenta en un conjunto de técnicas de optimización y compresión de modelos. La cuantización es, quizás, la más relevante, ya que consiste en reducir la precisión numérica de los pesos del modelo, pasando de números de punto flotante de 32 bits a enteros de 8 bits (INT8) o incluso menos. Esta técnica puede llegar a reducir el tamaño del modelo hasta en un 75% y disminuir la latencia de inferencia con una pérdida de precisión a menudo despreciable (Wang et al., 2025). Otras técnicas complementarias incluyen la poda (pruning), que elimina conexiones neuronales redundantes, y la destilación de conocimiento (knowledge distillation), donde un modelo grande y complejo ("maestro") entrena a un modelo más pequeño y eficiente ("estudiante") para que imite su comportamiento (Jaiswal & Gajjar, 2019).

El desarrollo de frameworks de software especializados, como TensorFlow Lite for Microcontrollers (TFLM) y, más recientemente, motores de inferencia como MicroFlow (Carnelos & Pasti, 2025), ha sido instrumental para facilitar este proceso. Sin embargo, el campo está en constante evolución, con la aparición de motores de inferencia alternativos como MicroFlow, basado en Rust, que busca mejorar la seguridad de la memoria y la eficiencia en dispositivos de 8 bits (Carnelos & Pasti, 2025), y plataformas de alto nivel como Edge Impulse, que abstraen gran parte de la complejidad del flujo de trabajo (Manjula et al., 2024). La investigación en este ámbito es fértil, con aplicaciones que van desde el mantenimiento predictivo (Alhusaini et al., 2025) hasta la agricultura inteligente (Gookyi et al., 2024), demostrando la versatilidad y el potencial del paradigma TinyML.

2.2.3. Plataformas Hardware y Enfoques de Visión Embebida

La elección de la plataforma hardware es un factor determinante en el diseño de cualquier sistema de visión embebida. La literatura recoge una variedad de opciones de bajo coste, cada una con un balance distinto entre capacidad de cómputo, consumo energético y precio. La Raspberry Pi, por ejemplo, es frecuentemente utilizada en estudios que requieren un sistema operativo completo y mayor flexibilidad, actuando como un ordenador de placa única capaz de ejecutar modelos de deep learning de complejidad moderada (Okano et al., 2025). Sin

embargo, su coste y consumo energético son considerablemente superiores a los de un microcontrolador.

En el extremo de la eficiencia y el bajo coste se encuentran los microcontroladores con capacidades de visión, siendo el ESP32-CAM una de las plataformas más populares. Su principal atractivo reside en la integración de un procesador de doble núcleo, conectividad Wi-Fi y una cámara en un único módulo de coste reducido (Aldahoul et al., 2023). Su idoneidad para tareas de TinyML ha sido validada en múltiples dominios, como la agricultura de precisión (Annadata et al., 2025) o la lectura de medidores analógicos (Paul et al., 2024). Sin embargo, su principal limitación es la escasa memoria SRAM (típicamente 520 KB), que impone retos de ingeniería significativos. Como demuestra Ben Aicha (2025), una implementación exitosa en el ESP32-CAM requiere una gestión cuidadosa de los desbordamientos de memoria de TensorFlow Lite, la alineación de memoria para la cuantización y el arbitraje de tareas en tiempo real entre la inferencia, la captura de imágenes y la comunicación inalámbrica.

No obstante, la evolución de esta familia de microcontroladores ha dado lugar a variantes arquitectónicamente superiores, diseñadas específicamente para mitigar estas limitaciones en aplicaciones de IA. El ESP32-S3, por ejemplo, representa un salto cualitativo significativo. Sus núcleos de procesador Xtensa LX7 dual-core no solo operan a una frecuencia de reloj superior (hasta 240 MHz), sino que incorporan extensiones de instrucciones vectoriales (SIMD). Esta característica proporciona una aceleración a nivel de hardware para las operaciones matriciales y de convolución que son la base de las redes neuronales, reduciendo drásticamente los tiempos de inferencia. Adicionalmente, variantes como la N16R8 del ESP32-S3 solventan el cuello de botella de la memoria, al integrar hasta 16 MB de Flash y 8 MB de PSRAM, una capacidad suficiente para alojar modelos de detección más complejos y búferes de imagen de mayor resolución. Este avance es soportado por un ecosistema de software maduro, con librerías como ESP-NN y ESP-DL optimizadas por el fabricante para aprovechar estas nuevas capacidades.

Frente a las soluciones basadas en aprendizaje profundo, los algoritmos de visión por computador "clásicos" persisten como una alternativa viable y computacionalmente eficiente. Estos métodos, disponibles en librerías optimizadas como OpenCV, se basan en el procesamiento de propiedades como el color, los contornos o las formas. Por ejemplo, la detección basada en el espacio de color HSV es una técnica común para segmentar objetos de

Jeisson Harvey Martínez Flórez

Guía metodológica para la implementación de sistemas de detección de objetos en microcontroladores ESP32-S3: Un enfoque basado en TinyML y arquitecturas Deep Learning

un color específico (Prasetyo et al., 2022). Su principal debilidad radica en su fragilidad ante la variabilidad del entorno (Isroni et al., 2023).

La literatura reciente ofrece métricas de rendimiento concretas para modelos TinyML en tareas de detección. Por ejemplo, Boussihmed et al. (2025) reportan un modelo para la detección de obstáculos con un tamaño de 1.93 MB, un mAP del 50% y una latencia de 96.2 ms. Arquitecturas especializadas para microcontroladores como FOMO (Faster Objects, More Objects) han sido propuestas para optimizar la detección en tiempo real en estas plataformas (Dharani et al., 2024). A continuación, se presenta la tabla 1 que sintetiza las características de ambos enfoques.

Tabla 1. Características de Enfoque Clásico vs. Enfoque TinyML.

Característica	Enfoque Clásico (Basado en Color/Contornos)	Enfoque TinyML (Basado en CNN)
Principio	Extracción manual de características (color, forma).	Aprendizaje automático de características a partir de datos.
Robustez	Baja. Sensible a cambios de iluminación, oclusión y fondo.	Alta. Generaliza mejor ante variaciones del entorno.
Complejidad de Desarrollo	Baja-Media. Requiere ajuste manual de parámetros.	Alta. Requiere dataset, entrenamiento y optimización.
Coste Computacional	Muy bajo. Operaciones aritméticas simples sobre píxeles.	Medio-Alto (para MCU). Operaciones matriciales complejas
Flexibilidad	Baja. Diseñado para un escenario específico.	Alta. Un mismo modelo puede detectar múltiples clases.

Fuente: (Prasetyo et al., 2022; Isroni et al., 2023; Mittal, 2024; Ben Aicha, 2025; Boussihmed et al., 2025)

La literatura es rica en implementaciones que demuestran la viabilidad de una u otra metodología de forma aislada. Se encuentran numerosos trabajos que despliegan con éxito modelos de TinyML en el hardware ESP32-CAM para resolver problemas concretos de visión artificial (Ben Aicha, 2025; Paul et al., 2024; Annadata et al., 2025). Asimismo, el valor del análisis comparativo como metodología de investigación en este campo está validado por estudios que evalúan diferentes plataformas de hardware (Gookyi et al., 2024) o el trade-off entre rendimiento y consumo energético en distintos dispositivos de bajo consumo (Morales-García et al., 2023).

2.2.4. Robótica Móvil de Bajo Coste (LCMR)

El desarrollo de la robótica móvil de bajo coste (*Low-Cost Mobile Robot*, LCMR) ha experimentado una transformación paradigmática con la llegada de sistemas embebidos de alta eficiencia, permitiendo que funciones que antes requerían estaciones de trabajo dedicadas se ejecuten ahora en microcontroladores de dimensiones reducidas. La plataforma ESP32-S3, en particular, se ha posicionado como una de las alternativas de microcontroladores embebidos usados como el núcleo tecnológico para estas aplicaciones, debido a su arquitectura optimizada para la inteligencia artificial en el borde (*Edge AI*).

Antes de entrar en detalles sobre la implementación de la percepción visual y el razonamiento espacial en la LCMR, es importante analizar su necesidad y utilidad específica en entornos interiores. El uso de LCMR en interiores se fundamenta en su capacidad para operar en espacios no estructurados, donde los obstáculos son dinámicos y la presencia humana es constante. A diferencia de los entornos industriales, donde las rutas pueden estar predefinidas, el hogar o la oficina tienen retos como cambios de iluminación, presencia de animales y mobiliario que cambia de posición (Mobile Robot Vision Expert, 2024; Li et al., 2019).

La integración de la visión estereoscópica o monocular avanzada permite a estos robots percibir, identificar e interactuar con su entorno de una manera que los sensores ultrasónicos tradicionales o los sensores de detección y rango de luz (Light Detection and Ranging, [LiDAR]) no pueden igualar. Mientras que un sensor de ultrasonido solo detecta la distancia a un objeto y un sensor LiDAR crea una nube de puntos que forman un modelo digital tridimensional, la visión permite distinguir si ese objeto es una persona que requiere ser seguida o una escalera que representa un peligro de caída. La implementación de una visión artificial robusta permite que estos robots realicen tareas de acompañamiento para personas mayores, vigilancia de seguridad o limpieza inteligente de manera autónoma y segura (Martínez et al., 2025).

Un componente esencial para el desarrollo de un LCMR es la capacidad de clasificar el entorno bajo una taxonomía que el sistema de control pueda interpretar. En este sentido, es fundamental diferenciar entre el contexto biológico y el contexto físico o estructural.

- **Contexto Biológico (Navegación Socialmente Consistente):** Referido a la detección y el seguimiento de agentes vivos, principalmente humanos y animales domésticos. En

la literatura académica, este campo se conoce como navegación socialmente consciente (*Socially-Aware Navigation*) o navegación consciente del humano (*Human-Aware Navigation*). El objetivo aquí no es solo evitar una colisión, sino comportarse de una manera que sea cómoda y predecible para los seres vivos circundantes (Nahum et al., 2025; Gao & Huang, 2022). La detección en el contexto biológico debe considerar la proxémica, que es el estudio del espacio personal y social que los humanos mantienen instintivamente. Un robot que invade el espacio íntimo de una persona (generalmente menos de 0.45 metros) causará incomodidad o ansiedad, incluso si no hay contacto físico. Por tanto, el sistema de visión debe proporcionar la indicación de que observa una persona, sino también datos de posición y orientación precisos para que el planificador de rutas ajuste el comportamiento del robot (Kang et al., 2024). En el caso de las mascotas (específicamente perros), el contexto biológico adquiere una dimensión de incertidumbre mayor. Las mascotas suelen moverse de forma menos predecible que los humanos y pueden aproximarse al robot con curiosidad. El modelo de detección debe ser capaz de identificar a estos agentes para activar modos de operación de "baja velocidad" o "parada de seguridad" (Smith, 2023).

- **Contexto Físico y Estructural (Affordance):** El contexto físico o estructural engloba los elementos inanimados que definen la topología del entorno. Esto incluye obstáculos genéricos (muebles, cables), elementos de transición (puertas) y riesgos estructurales (escaleras). En robótica, estos elementos se analizan bajo el prisma de las "affordances" o posibilidades de acción (Manganelli, 2013). Por otro lado, un mapa semántico es la representación que el robot construye de este contexto físico. A diferencia de un mapa geométrico simple (que solo muestra espacios libres y ocupados), el mapa semántico asigna significado a los objetos. Por ejemplo, una "puerta" no es simplemente un obstáculo; es un objeto que puede estar en estado abierto o cerrado, permitiendo o impidiendo la transición entre nodos de navegación. Las "escaleras", por otro lado, son detectadas como límites de navegabilidad para robots de ruedas, disparando una alerta de riesgo que el sistema de control debe gestionar para evitar daños graves (Kachana, 2025; Li et al., 2019).

Tanto la navegación socialmente consistente como el Affordance, son viables a nivel técnico gracias a la implementación de la visión artificial. Este campo tiene una variedad de

Guía metodológica para la implementación de sistemas de detección de objetos en microcontroladores ESP32-S3: Un enfoque basado en TinyML y arquitecturas Deep Learning paradigmas en la interpretación de imágenes; los más conocidos son: la clasificación, la detección y la segmentación. A continuación, se analiza cada una de ellas y su aplicabilidad en LCMR.

- **La Clasificación de Imágenes:** Responde a la pregunta “¿qué hay en esta imagen?”; aunque es la técnica computacionalmente más ligera, su utilidad en LCMR es limitada. Saber que hay una persona en el campo de visión no ayuda al robot a evitarla si no sabe dónde está ubicada; en otras palabras, la clasificación carece de la información espacial necesaria para el control de trayectoria (GeoWGS84 AI, 2024).
- **La Segmentación Semántica:** Asigna una clase a cada pixel de la imagen, permitiendo identificar la forma exacta de los objetos. Aunque proporciona una riqueza de datos muy importante para un mapeo detallado del entorno, la demanda de memoria RAM y potencia de procesamiento es excesiva para los microcontroladores de bajo coste, como el ESP32-S3. La segmentación requiere mantener mapas de activación de alta resolución a lo largo de las capas de la red, lo que satura rápidamente los recursos (Keymakr, 2024; Long et al., 2019).
- **La Detección de Objetos:** Localiza y clasifica elementos específicos mediante cajas delimitadoras (*bounding boxes*). Esta técnica proporciona las coordenadas relativas (x, y) y el tamaño (w, h) del objeto, permitiendo al robot calcular distancias y ángulos de giro de manera eficiente. La detección otorga un equilibrio ideal ya que proporciona la información espacial para la navegación pero con una carga computacional, que mediante optimizaciones de hardware y software, es perfectamente manejable por microcontroladores de bajo coste (Fadhullah, 2023).

2.2.5. Percepción y Navegación en Robótica Móvil de Interiores

Uno de los mayores retos en el contexto de la robótica móvil de interiores es la autonomía en entornos no estructurados tan complejos y dinámicos; en él convergen la percepción sensorial, el control cinemático y las limitaciones computacionales para definir el éxito de una plataforma robótica. El Robot Autónomo Móvil (AMR, por sus siglas en inglés) debe ser capaz de interpretar su entorno para realizar tareas de localización, mapeo y, fundamentalmente,

evitar obstáculos con el fin de garantizar la seguridad tanto del dispositivo como de los seres vivos que cohabitan en dicho espacio.

La precisión de la detección de objetos no es meramente un requisito técnico, sino la premisa que asegura que el AMR pueda completar sus misiones en entornos donde la precisión a nivel de centímetros es necesaria para una navegación segura. La investigación académica ha priorizado en el desarrollo de sistemas de visión artificial y sensores de rango que permiten esa interpretación tridimensional del espacio a partir de datos unidimensionales, bidimensionales o de nubes de puntos, enfrentándose a retos como la variabilidad lumínica, las oclusiones y las restricciones de hardware en LCMR (Messbah et al., 2025; Liu et al., 2024; Kurup y Patil, 2020).

2.2.5.1. Rango de Detección de Objetos

La determinación del rango de detección óptimo para robots móviles en interiores no constituye una cifra estática, sino un equilibrio entre la velocidad de operación, la latencia de procesamiento del sistema de percepción y la capacidad de maniobra de la plataforma. Un alcance insuficiente compromete la seguridad al reducir el tiempo de reacción ante objetos. Por el contrario, un rango excesivo incrementa la carga computacional y la probabilidad de ruido al procesar objetos irrelevantes para la trayectoria planificada (Kim et al., 2025; Budiharto et al., 2012). A continuación, se discuten dos aspectos fundamentales relacionados con el rango de detección.

- **Caracterización de sensores y rangos efectivos:** En el ámbito académico y experimental, se han definido diversos umbrales de detección en función de la tecnología de sensores integrada, como se detalla en la Tabla 2. Los sensores ultrasónicos, valorados por su bajo costo y robustez ante variaciones lumínicas, presentan rangos de operación entre los 2 mm y los 4 m. No obstante, la literatura técnica sugiere que, para optimizar la fluidez en la navegación, es conveniente restringir el área de interés a un radio funcional. En sistemas de evitación de obstáculos basados en lógica difusa, por ejemplo, se ha determinado que un radio de detección de aproximadamente 2,2 m resulta eficaz para mitigar el ruido proveniente de objetos ajenos a la trayectoria crítica del robot. De manera complementaria, los sensores de infrarrojos (IR) ofrecen una precisión elevada en rangos cortos, situados usualmente entre los 40 mm y los 300 mm. Esta tecnología es esencial en las fases de aproximación

final o en sistemas de parada de emergencia, donde la resolución milimétrica prevalece sobre el alcance de larga distancia. En plataformas de investigación, como el Robotino de cuarta generación, se integran estos dispositivos para asegurar la detención del vehículo a una distancia predefinida con alta fidelidad, vinculando las propiedades electroópticas del sensor con el algoritmo de control.

- La zona de seguridad y la cinemática del robot:** Shim y Kim (2018), Kim et al. (2025) y Zheng et al. (2025) establecen parámetros críticos que funcionan como criterios de seguridad en la navegación. En entornos experimentales con robots de servicio, se ha determinado una distancia de seguridad (d_{safe}) de 120 cm, umbral en el cual el sistema debe iniciar maniobras evasivas. Asimismo, se define una distancia mínima de 40 cm como el límite de detención absoluta para prevenir colisiones. Estos valores se vinculan a la velocidad del robot (R_v), que oscila entre 0,2 m/s y 0,4 m/s, y a la velocidad estimada de los obstáculos móviles (O_v), que puede alcanzar los 0,8 m/s. El cálculo del rango óptimo integra el modelo cinemático de la plataforma; específicamente, en vehículos de tracción diferencial, la capacidad de giro y frenado define el tiempo de detección necesario. Bajo un ciclo de procesamiento, por ejemplo, de 220 ms, cualquier objeto detectado a una distancia inferior a la recorrida en dicho intervalo representa un riesgo operativo. Por lo tanto, el rango óptimo constituye la distancia requerida para que el sistema identifique el objeto, planifique una ruta alternativa y ejecute la maniobra antes de vulnerar el perímetro de seguridad de 40 cm.

Tabla 2. Caracterización de Sensores y Rangos Efectivos de Detección en AMR

Tecnología del Sensor	Rango Típico de Operación	Aplicación Sugerida en Interiores	Ventajas/Limitaciones
Ultrasonido (sonar)	2 mm a 4 m	Navegación general y detección de proximidad.	Bajo coste, afectado por la temperatura y superficies absorbentes.
Infrarrojo (IR)	40 mm a 300 mm	Parada de emergencia y ajuste fino de posición.	Alta precisión en corto alcance, sensible a la luz ambiental.
LiDAR	Hasta 8 m o más	Mapeo (SLAM) y planificación de rutas globales.	Alta frecuencia de escaneo (75 Hz), excelente resolución angular.

Cámaras de Profundidad	0,5 m a 5 m	Reconocimiento de objetos 3D y evitación dinámica.	Proporciona datos semánticos y espaciales, requiere alta capacidad de cómputo.
-------------------------------	-------------	--	--

Fuente: Elaboración propia a partir de Ma (2023); Klimenda et al. (2021)

2.2.5.2. Factores determinantes en la cantidad y calidad de objetos detectados

La capacidad de un AMR para detectar múltiples objetos en interiores depende de factores ambientales y técnicos que condicionan la señal visual, resumidos en la Tabla 3 a partir de las investigaciones de Zheng et al. (2025); Waga et al. (2025); Hoang (2025); Patruno et al., (2024); Santos y Romero (2022); Singh et al. (2022) y Hernández et al. (2016). Estos elementos permiten definir las expectativas de rendimiento y diseñar sistemas robustos. A continuación, se analizan dos factores fundamentales:

- **Condiciones de iluminación:** La iluminación es el factor más crítico en la visión artificial. Los sensores de imagen poseen un rango dinámico limitado, por lo que su sensibilidad se degrada ante la escasez de luz o reflejos especulares. En entornos industriales, por ejemplo, con superficies reflectantes, se requiere el diseño de sistemas de iluminación específicos —como carcasas con tiras de LED— para resaltar las microestructuras del suelo y mitigar los "puntos calientes" que generan errores en la odometría visual. Una iluminación deficiente no solo reduce la detección, sino que aumenta el tiempo de exposición, lo que provoca desenfoque por movimiento (blur) e aumenta el riesgo de invalidar los resultados.
- **Geometría y perspectiva:** La proyección de objetos tridimensionales en planos 2D introduce retos como la oclusión, fenómeno que fragmenta los cuadros delimitadores (bounding boxes). Los algoritmos actuales emplean modelos de inferencia contextual para estimar las partes ocultas. Asimismo, la orientación del objeto respecto a la cámara influye en la extracción de rasgos; rotaciones complejas en el eje 3D pueden reducir la confianza del sistema si difieren de los datos de entrenamiento. Arquitecturas como Mobile-EFSSD, que integran mecanismos de atención (ECA) y fusión de características multiescalar, optimizan significativamente la detección en escenas complejas de interior.

Tabla 3. Factores determinantes de cantidad y calidad en detección de objetos

Factor Ambiental	Efecto en la Detección	Estrategia de Mitigación
Iluminación Variable	Pérdida de rasgos característicos y aumento de ruido.	Iluminación activa integrada, normalización de histogramas.
Oclusión Mutua	Objetos que bloquean parcialmente a otros, ocultando sus bboxes.	Redes de pirámide de características (FPN, por sus siglas en inglés), razonamiento contextual.
Fondos Complejos	Confusión entre el objeto y texturas similares en el entorno.	Segmentación semántica, filtrado por planos de profundidad.
Deformación y Articulación	El cambio de forma de los objetos (ej. Humanos) dificulta el emparejamiento.	Entrenamiento con aumentación de datos masiva y modelos de aprendizaje profundo.

Fuente: Elaboración propia a partir de Zheng et al. (2025); Waga et al. (2025); Hoang (2025); Patruno et al., (2024); Santos y Romero (2022); Singh et al. (2022) y Hernández et al. (2016)

2.2.5.3. Metodologías para estimación de distancia mediante visión monocular

La estimación de profundidad a través de una única cámara (visión monocular) representa un reto central en los AMR, y, en especial, en la LCMR. Este desafío surge de la pérdida inherente de información tridimensional durante la proyección de la imagen. Para recuperar la dimensión de distancia (Z) a partir de cuadros delimitadores (bounding boxes), se emplean desde modelos geométricos hasta técnicas de aprendizaje supervisado; la Tabla 4 sintetiza los diferentes métodos de estimación. Aunque la presente investigación no aborda el cálculo de profundidad o estimaciones de distancia, se describen brevemente las técnicas posibles para esta tarea. El objetivo es contextualizar los requerimientos técnicos de las imágenes capturadas por el sistema de visión monocular.

- **Modelo de cámara estenopeica y restricción del plano de tierra:** La base matemática de estas estimaciones reside en el modelo de cámara estenopeica (pinhole). La relación entre un punto del espacio real y su proyección se define mediante la matriz de proyección P , que integra parámetros intrínsecos —como la distancia focal y el punto principal— y extrínsecos —como la altura y el ángulo de inclinación de la cámara—. La Ecuación 1, apoyado por la Figura 1, describen lo fundamental del modelo, Donde s representa un factor de escala que introduce ambigüedad. En

entornos de robótica móvil de interior, se asume que el objeto se desplaza sobre el mismo plano que el robot ($Z_\omega = 0$). Bajo esta restricción, existe una correspondencia directa entre la coordenada vertical del píxel inferior del cuadro delimitador y la distancia relativa al objeto.

$$s \cdot \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = P \cdot \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} \quad \text{Ecuación (1)}$$

- **Cálculo mediante geometría de la imagen:** Al detectar un cuadro delimitador, el punto de mayor relevancia para el cálculo es el centro de su base, el cual representa el contacto del objeto con el suelo. Si se conoce la altura de montaje de la cámara (H) y su ángulo de inclinación (θ), es posible aplicar funciones de transformación de coordenadas imagen-a-vehículo. Para escenarios donde el eje óptico es paralelo al suelo, se aplica una fórmula simplificada derivada de la similitud de triángulos descrita en la Ecuación 2. En esta expresión, f es la distancia focal en píxeles y y es la distancia vertical desde el punto principal de la imagen hasta la base del cuadro. No obstante, en aplicaciones reales la cámara suele presentar una inclinación para captar objetos próximos. En tales casos, se utiliza la homografía plana para mapear el plano de la imagen al plano del suelo del vehículo. Este método exige una calibración precisa, ya que desviaciones mínimas en la inclinación pueden inducir errores significativos en el cálculo (Jalalnezhad et al, 2025).

$$Z = \frac{f \cdot H}{y} \quad \text{Ecuación (2)}$$

- **Enfoques basados en aprendizaje profundo:** Investigaciones recientes proponen el uso de redes neuronales multicapa para estimar la distancia sin depender exclusivamente de la geometría de la escena. Un ejemplo destacado es la arquitectura DisNet, que procesa un vector de características (Ecuación 3) de seis dimensiones extraído de un detector como YOLO (You Only Look Once). Donde B_h , B_w y B_d son la altura, el ancho y la diagonal de la caja, y C_h , C_w , C_b son las dimensiones físicas promedio de la clase del objeto. Al usar proporciones de la caja delimitadora respecto a la resolución de la imagen, el modelo DisNet puede reutilizarse con diferentes

Jeisson Harvey Martínez Flórez


Guía metodológica para la implementación de sistemas de detección de objetos en microcontroladores ESP32-S3: Un enfoque basado en TinyML y arquitecturas Deep Learning
 cámaras sin necesidad de reentrenamiento (Zheng et al., 2024; Shi et al., 2023; Haseeb et al., 2018).

$$v = \left[\frac{1}{B_h}, \frac{1}{B_w}, \frac{1}{B_d}, C_h, C_w, C_b \right] \quad \text{Ecuación (3)}$$

Tabla 4. *Métodos de estimación de distancia por visión monocular*

Método de Estimación	Requisitos de Información	Precisión y Robustez
Similitud de Triángulos	Tamaño real del objeto conocido o altura de cámara y focal.	Alta precisión si los datos son exactos; falla si el objeto cambia de tamaño.
Homografía Plana	Parámetros extrínsecos (altura, pitch) y cámara calibrada.	Eficiente para objetos en el suelo; sensible a vibraciones y baches.
Redes Neuronales	Características de la bbox (altura, ancho, centro)	No requiere parámetros de cámara explícitos; depende de la calidad del dataset.
Flujo Óptico / Tamaño Temporal	Cambio en el tamaño de la bbox a lo largo del tiempo.	Útil para objetos desconocidos; requiere movimiento constante.

Fuente: Elaboración propia a partir de Coscia et al. (2026); Yu et al. (2025); Jalalnejhad et al (2025); Zheng et al. (2024); Shi et al. (2023); MathWorks (2023); Bhoi (2019); Haseeb et al. (2018)

Figura 1. Modelo de Cámara Estenopeica y Restricción del Plano de Tierra

Nota: Imagen generada mediante el modelo de inteligencia artificial Nano Banana Pro (Google, 2026) a partir de una descripción técnica del modelo de proyección definido por Coscia et al. (2026); Yu et al. (2025); MathWorks (2023); Bhoi (2019).

2.2.6. Ingeniería de Datos para la Percepción de Robots Móviles de Bajo Coste

La autonomía en la robótica móvil de interiores se fundamenta en la capacidad del sistema para interpretar estímulos visuales complejos y traducirlos en decisiones cinemáticas seguras. El uso de la visión computacional basada en aprendizaje profundo (Deep Learning), debido a su capacidad para extraer información semántica rica de una sola imagen, se está proliferando. Sin embargo, la transición hacia plataformas de bajo coste introduce restricciones rigurosas que obligan a reconsiderar cada etapa del ciclo de vida de los datos, desde la captura inicial hasta las estrategias de aumentación y el etiquetado de las cajas delimitadoras (bboxes). A continuación, se analizan los criterios técnicos, encontrados en la literatura reciente, para conformar datasets robustos que permiten la navegación autónoma, la estimación de distancia monocular y el despliegue eficiente de modelos de visión artificial TinyML en entornos no estructurados.

2.2.6.1. Criterios de Selección y Captura de Imágenes

La conformación de un conjunto de datos (dataset) para robótica de interiores requiere representatividad estadística. La literatura académica subraya que la capacidad de generalización de una red neuronal convolucional (CNN) depende de la fidelidad con la que el entrenamiento capture la distribución del entorno operativo real. Además, también sugiere que, ante la imposibilidad de recolectar millones de imágenes reales, la estrategia ideal es el pre-entrenamiento en grandes datasets genéricos (como *COCO* o *ImageNet*) seguido de una Transferencia de Aprendizaje (*Transfer Learning*) y ajuste fino (*fine-tuning*) con un dataset pequeño (de 1,000 a 5,000 imágenes) capturado estrictamente en el entorno operativo del robot (Messbah et al., 2025; Wozniak et al., 2025; Huang et al., 2024).

En la Tabla 5 se clasifican tres tipos de fuentes de datos identificadas en la revisión documental. A continuación, se analiza la utilidad de las imágenes de "catálogo" frente a las capturadas en entornos operativos reales:

- **Limitaciones de las imágenes de catálogo:** Estas imágenes, que muestran objetos aislados sobre fondos neutros e iluminación ideal, resultan deficientes para la robótica móvil. En la navegación *indoor*, este formato induce "ceguera contextual", pues el sistema asocia la ausencia de texturas perimetrales con la identidad del objeto. Al desplegar el modelo, la complejidad visual del entorno real se interpreta como ruido o se fusiona con el objeto, lo que eleva la tasa de falsos negativos. La recuperación de imágenes reales de bases de datos extensas es más efectiva, ya que conservan las imperfecciones necesarias para separar la figura del fondo en condiciones ruidosas.
- **Superioridad del contexto operativo real:** Azurmendi et al. (2023) y Foroughi et al. (2021) presentan ejemplos claros en donde, para dispositivos de bajo coste, es fundamental emplear datos egocéntricos; este es un enfoque que garantiza la integración de factores ambientales que determinan la calidad de la detección:
 - *Perspectiva y Geometría:* La cámara, montada a una altura entre 10 y 50 cm, genera una perspectiva de "gusano". Esta deforma los objetos de manera distinta a las capturas realizadas a la altura de los ojos humanos.
 - *Variabilidad lumínica:* Los interiores presentan cambios bruscos de iluminación y temperatura de color. Los sensores de bajo coste son sensibles a estos cambios, los cuales generan ruido térmico y saturación que el modelo debe aprender a gestionar.

- **Propiedades del Suelo:** En la estimación de distancia monocular, la relación entre el objeto y el plano del suelo es esencial. Las imágenes reales permiten que la red aprenda la “signatura visual” del contacto entre el objeto y la superficie.

Tabla 5. *Tipos de Datasets aplicables para robótica de interiores*

Tipo de Dataset	Representatividad del Fondo	Calidad de Perspectiva	Utilidad en plataformas de Bajo Coste
Catálogo (Fondo Blanco)	Nula	Inadecuada (Altura de ojo)	Muy baja; genera sesgos severos.
Sintético (Simulación)	Media-Alta	Ajustable	Alta para pre-entrenamiento.
Real Operativo (Egocéntrico)	Máxima	Exacta (Altura de Robot)	Óptima; máxima robustez.

Fuente: Elaboración propia a partir de Messbah et al. (2025); Wozniak et al. (2025); Zheng et al. (2025); Huang et al. (2024); Azurmendi et al. (2023); Foroughi et al. (2021)

2.2.6.2. Criterios de ajuste de Bounding Boxes

Tras la captura de la imagen, la calidad de la anotación determina la precisión de la localización del sistema. En la robótica de bajo coste, donde las resoluciones de entrada suelen ser limitadas, un cuadro delimitador (bounding box o bbox) mal ajustado no solo representa un error de clasificación, sino que constituye un fallo crítico en la estimación de distancia que puede derivar en colisiones. A continuación, se amplían los criterios más relevantes.

- **Calidad y precisión del ajuste:** Es imperativo que las bboxes se ajusten estrictamente al contorno visible del objeto (*tight*). En este sentido, el borde inferior del cuadro es el dato de mayor valor para la visión monocular. Si la anotación incluye un margen excesivo de píxeles del suelo, los cálculos de distancia u otras utilidades derivadas de la percepción podrían ser erróneas; por ejemplo, el robot ejecutará maniobras de evasión innecesarias (Alenjareghi et al., 2025).
- **Consistencia en la gestión de oclusiones:** La robustez del sistema depende de la coherencia en el manejo de zonas no visibles. Al respecto, se identifican dos enfoques:
 - *Anotación modal:* Etiqueta exclusivamente el área visible del objeto. Se considera la opción óptima para sistemas de procesamiento limitado, ya que

reduce la carga computacional al evitar que el modelo infiera información inexistente.

- *Anotación amodal*: Etiqueta el objeto completo asumiendo su forma oculta. Aunque favorece el razonamiento contextual en plataformas de alta gama, en sistemas de bajo coste suele degradar la precisión media (*mean Average Precision* o *mAP*) debido a la baja densidad de información semántica.
- **Niveles de incertidumbre por visibilidad**: Un objeto es detectable de forma confiable si su área visible representa al menos entre el 15% y el 20% de su superficie total, o si conserva una dimensión lineal superior al 6% respecto a la resolución total de la imagen. Si la oclusión supera estos umbrales, se recomienda omitir el etiquetado para evitar que el modelo asocie rasgos ambiguos con el objeto (Li y Huang, 2026).
- **Desafíos de escala relativa**: Zhang et al. (2025) y Iqra et al. (2024) por sus experiencias en detección de objetos pequeños, mencionan que escala del objeto respecto al área total de captura introduce anomalías como:
 - *Objetos minúsculos*: aquellos que ocupan menos del 1% del área de la imagen. Debido al submuestreo progresivo en los modelos de Deep Learning (*downsampling*), estos elementos pueden reducirse a una unidad mínima en el mapa de características, imposibilitando su detección.
 - *Objetos gigantes*: Ocurren cuando un objeto ocupa más del 80% del área de captura. En este escenario, la falta de bordes definidos dificulta la convergencia del optimizador, lo que podría indicar, por ejemplo, que el sistema robótico ha comprometido la distancia mínima de seguridad.
- **Densidad de objetos y latencia en el procesamiento**: Cada detección debe someterse a una Supresión de No Máximos (NMS, por sus siglas en inglés) para eliminar redundancias. Dado que el tiempo de ejecución del NMS aumenta de forma no lineal respecto al número de candidatos, este proceso puede transformarse en un cuello de botella para el procesamiento en tiempo real. En consecuencia, para plataformas con recursos limitados, la literatura sugiere una densidad ideal de 2 a 5 objetos por captura. Superar este umbral eleva la latencia de posprocesamiento, comprometiendo la respuesta ante obstáculos móviles. Recientemente, para mitigar este efecto, se han desarrollado arquitecturas NMS-Free, tal es el caso de YOLO26, las cuales optimizan el

2.2.6.3. Dinámica Espacial y Estadística

La relación entre los objetos dentro de un conjunto de datos influye significativamente en la capacidad de un sistema robótico para interpretar la escena de manera profunda, trascendiendo el mero reconocimiento de patrones de píxeles aislados. Así lo detalla la literatura consultada, donde se priorizan los siguientes factores como determinantes en dicha interpretación:

- **La co-ocurrencia como prioridad cognitiva:** En entornos de interiores, la distribución de los objetos no es aleatoria. Gunji et al. (2024) validan que esta co-ocurrencia puede ser explotada mediante modelos de lenguaje de gran escala (LLM, por sus siglas en inglés) para generar matrices de probabilidad que optimicen la comprensión de escenas tridimensionales. Por ejemplo, si un robot detecta una mesa con un alto nivel de confianza, el sistema puede ajustar sus umbrales internos para favorecer la identificación de sillas en la proximidad, lo que incrementa la robustez ante oclusiones. No obstante, se debe advertir que un dataset con una co-ocurrencia excesivamente rígida puede inducir un sesgo perjudicial (Gunji et al., 2024). En tales casos, el robot podría fallar al reconocer un objeto fuera de su contexto habitual. Para mitigar este riesgo y mejorar la equidad y el rendimiento en cámaras de borde (*edge cameras*), se sugiere que los criterios de selección incluyan un margen de casos fuera de contexto (Nguyen et al., 2024). Esto garantiza que el modelo aprenda rasgos morfológicos puros e independientes.
- **Impacto de la relación de aspecto en la función de pérdida:** La relación de aspecto (*aspect ratio*) de las cajas delimitadoras afecta directamente la convergencia del entrenamiento. Debido a que los objetos en interiores varían desde formas verticales hasta horizontales, un desequilibrio hacia formas cuadradas dificulta que la función de pérdida de intersección sobre unión (IoU) penalice correctamente las desviaciones en objetos alargados. Para resolver esta limitación, Ravi et al. (2022) recomiendan el uso de funciones de pérdida avanzadas como la *Complete-IoU* (CIoU) o la

Bounding-Box-IoU (BIOU), las cuales consideran explícitamente la consistencia de la relación de aspecto.

- **Concentración espacial y detección de objetos pequeños:** La distribución de las anotaciones en el plano de la imagen debe ser uniforme para evitar el sesgo hacia el centro (*center bias*), el cual es inaceptable para la robótica móvil. Como señalan Khalili y Smyth (2024), mejorar los modelos de detección (como YOLOv8) para objetos pequeños en escenas de tráfico o aéreas requiere que las anotaciones cubran todas las zonas de la imagen. Un dataset óptimo debe asegurar la detección de elementos que ingresan en el campo de visión, incluso cuando sus cajas delimitadoras están parcialmente fuera de los límites del cuadro (Liu et al., 2025).

2.2.6.4. Protocolos de Augmentación de Datos

La aumentación de datos permite expandir artificialmente el conjunto de datos, una práctica esencial cuando se trabaja con modelos de navegación robótica basada en visión que requieren una transferencia efectiva de entornos simulados a reales (sim-to-real). No obstante, en el ámbito de la robótica móvil, existe una distinción fundamental entre las técnicas que preservan la integridad geométrica y aquellas que la corrompen.

- **Aumentaciones fotométricas (ideales para interiores):** Estas técnicas modifican el color y la intensidad sin alterar la posición de los píxeles, lo que las hace totalmente seguras para robots que dependen de la geometría de la imagen para el cálculo de distancias. Según Wu et al. (2023), el escalamiento masivo de estas aumentaciones es prioritario para mejorar la precisión en tareas de estimación y completado de profundidad monocular. Algunas de estas son:
 - *Ajuste de brillo y contraste:* Resulta fundamental para simular transiciones entre habitaciones bien iluminadas y rincones oscuros, permitiendo que los sistemas de conducción autónoma en tiempo real mantengan su operatividad.
 - *Conversión al espacio de color HSV:* Al manipular el matiz (*Hue*) y la saturación (*Saturation*), el modelo disminuye su dependencia del color específico de un objeto y prioriza su forma y textura, lo cual es vital para la generalización en entornos diversos.

- **Ruido de sensor y desenfoque:** Dado que hardware de bajo coste, como el ESP32-S3, generalmente captura imágenes con ruido electrónico y desenfoque por movimiento (*motion blur*), inyectar estos artefactos durante el entrenamiento constituye una "vacuna" necesaria para mantener el rendimiento (mAP) en condiciones reales.
- **Aumentaciones geométricas (críticas y peligrosas):** Las transformaciones geométricas pueden resultar perjudiciales si se aplican sin considerar la física de la cámara. Al respecto, Guan et al. (2024) proponen métodos de remuestreo geométrico que buscan optimizar la detección 3D monocular sin introducir distorsiones que invaliden las leyes de la perspectiva. Por ejemplo:
 - **Rotación aleatoria:** Es una de las técnicas más riesgosas, ya que la orientación del horizonte y la verticalidad de los objetos son constantes críticas en la navegación. Si se entrena al robot rotando imágenes excesivamente, el modelo pierde la capacidad de utilizar la posición vertical de la base de la caja delimitadora (bbox) para estimar la profundidad. Autores como Lopez-Francos et al. (2025) recomiendan únicamente rotaciones leves ($\pm 3^\circ$ a $\pm 5^\circ$) para simular el balanceo del chasis sobre suelos irregulares.
 - **Recorte (*cropping*) y escalado:** Al aplicar estas técnicas, se altera virtualmente la distancia focal del sistema. Si el algoritmo de distancia asume una focal fija (ej. 2.8 mm) pero el entrenamiento empleó imágenes con recortes o zoom digital, se producirán errores masivos en la estimación de profundidad.
 - **Flipping horizontal:** Como señalan Abou Akar et al. (2025) en su desarrollo de conjuntos de datos sintéticos a gran escala, esta es la única aumentación geométrica permitida de forma extensiva, pues la simetría lateral suele conservarse en la mayoría de los entornos industriales y domésticos sin afectar la perspectiva monocular

2.3.Conclusiones

El análisis del contexto y la revisión sistemática del estado del arte convergen en una serie de conclusiones fundamentales que delimitarán la necesidad, originalidad y relevancia de la presente investigación.

El estudio del contexto revela una transición paradigmática en el ámbito de la computación y los datos, impulsada por el IoT. La arquitectura centralizada en la nube, si bien ha sido fundamental para el desarrollo de la inteligencia artificial, es insuficiente para satisfacer demandas de aplicaciones en tiempo real, donde la latencia, el consumo de ancho de banda y la privacidad son críticos. El Edge Computing responde a este problema, y en especial la Edge Intelligence se presenta como un enfoque nuevo para descentralizar el procesamiento y ejecutar inferencias de IA directamente en los dispositivos IoT.

En este marco, TinyML habilita la ejecución de algoritmos de Machine Learning en microcontroladores de muy bajo coste y consumo energético, aspectos de gran rigor para las aplicaciones prácticas de IA. La cuantización y la poda son técnicas de optimización que facilitan la puesta en marcha del TinyML, por lo que la convergencia hacia las técnicas de visión por computador embebido está impactando directamente áreas como la robótica móvil y la robótica inteligente. Sectores como la logística, la industria y, de forma particular, el ámbito educativo, están siendo democratizados en la aplicación de este enfoque práctico.

Paralelamente, el estado del arte da cuenta de diferentes estudios y demostraciones de uso en la detección de objetos con plataformas de hardware con recursos limitados. Así mismo, de la coexistencia de las dos metodologías principales: clásica de visión por computador a través de librerías optimizadas como OpenCV (basada en procesamiento de características como color y contornos) y moderna (basado en despliegue de Redes Neuronales Convolucionales - CNN). De ésta última, el estado del arte valida su implementación en microcontroladores como el ESP32, Raspberry pi y otras como Arduino Sense Nano.

A pesar de la literatura extensa relacionada con la demostración de la viabilidad de cada enfoque por separado, la revisión sistemática, realizada hasta la fecha, revela la falta de conocimiento de carácter comparativo. La gran mayoría de investigaciones se centran en implementar una única solución —sea clásica o de TinyML— para una tarea específica, sin ofrecer el contraste directo y cuantificable con la alternativa, bajo condiciones experimentales controladas. Específicamente, el vacío se encuentra en la comparativa metodológica, empírica y educativa.

Además, no se encontraron estudios que implementen y evalúen ambas soluciones sobre una plataforma de hardware idéntica, utilizando un conjunto unificado y riguroso de métricas de rendimiento como: precisión de detección, latencia de inferencia, uso de memoria (RAM y Flash) y la robustez del sistema frente a perturbaciones del entorno.

En consecuencia, este Trabajo Final de Estudios se postula como la alternativa que presente dicho estudio comparativo, desde un enfoque práctico, empírico y metodológico a través del diseño y ejecución de un prototipo móvil robótico de bajo coste utilizado como “laboratorio controlado” para evaluar de manera cuantitativa y cualitativa el rendimiento de un enfoque de visión artificial clásico frente a un modelo de inteligencia artificial basado en TinyML.

Los resultados de esta investigación no solo aportarán conocimiento técnico de valor sobre la eficiencia relativa de ambas tecnologías en la robótica de bajo coste, sino que también servirá como la base fundamental para el desarrollo de una guía metodológica orientada al público de habla hispana, dentro del contexto de la ingeniería con especialidad mecatrónica, electrónica y computacional.