

Análisis Exploratorio de Datos (EDA)

En esta sección del notebook se realiza un análisis exploratorio para el dataset de detección de obstáculos en interiores conformado, abarcando los siguientes pasos:

Estructura del EDA:

- **Paso 1:** Unificación de Datasets base
- **Paso 2:** Análisis Técnico del Dataset (resolución, integridad, duplicados, estadísticas de píxeles)
- **Paso 3:** Distribución de Clases (conteos, co-ocurrencia, comparación train/val/test)
- **Paso 4:** Geometría de Bounding Boxes (tamaño, aspect ratio, heatmap espacial, anchors optimizados)
- **Paso 5:** Complejidad de Escena (densidad de objetos, oclusión/IoU)
- **Paso 6:** Inspección Visual Cualitativa (muestreo aleatorio, detección de anomalías)

```
In [1]: # Auto-reload: recarga módulos automáticamente al detectar cambios en
%load_ext autoreload
%autoreload 2

# Librerías
import os
import sys
import json
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
import cv2
import random
import hashlib
import yaml
from pycocotools.coco import COCO
from sklearn.cluster import KMeans

# Rutas base
base_dir = "/Users/admin/Documents/TFM_UNIR/01_ING_DATOS"
dataset_path = os.path.join(base_dir, "Datasets", "dataset_maestro_uni

# Añadir path de utilidades
src_path = os.path.join(base_dir, "src")
if src_path not in sys.path:
    sys.path.insert(0, src_path)
from utils_eda import *

# Directorio de salida para guardar reportes
output_dir = os.path.join(base_dir, "Reports")
```

Paso 1: Unificación de Datasets Base

Este paso inicial del tratamiento de datos se realizó para unificar los 15 datasets utilizados como fuente de datos. El objetivo es consolidar las imágenes y etiquetas en un único Dataset Maestro con un mapeo de clases unificado, en formato YOLO, serializando las imágenes como img_000001, img_000002, ...

El proceso realizado es:

1. Lee data.yaml de cada dataset → extrae clases locales.
2. Normaliza nombres de clases (lowercase + singular + excepciones).
3. Construye mapeo global unificado de clases.
4. Mueve imágenes y reescribe labels con el nuevo class_id.
5. Genera data.yaml unificado + log de trazabilidad + análisis de distribución.


Para lo cual fue generado el script `Union_dataset.py` y entrega el dataset curado en la carpeta

`./01_ING_DATOS/Datasets/dataset_maestro_unificado`. Los datasets utilizados para la creación de este Dataset Maestro son:

```
DATASETS = [
    "Roboflow_dataset10-yolo26",
    "Roboflow_Dataset11-yolo26",
    "Roboflow_Dataset12-yolo26",
    "Roboflow_Dataset13-stair-yolo26",
    "Roboflow_Dataset14-stair-yolo26",
    "Roboflow_Dataset15-MyHome-yolo26",
    "Roboflow_Dataset8-IndoorObstacleDetection-yolo26",
    "Roboflow_Door-Detection-yolo26",
    "Roboflow_DoorDetection-yolo26",
    "Roboflow_Doors0D-yolo26",
    "Roboflow_ObstacleUnique-yolo26",
    "Roboflow_obstacle-avoidnace-yolo26",
    "Roboflow_obstacle-door-person-yolo26",
    "Roboflow_obstacle-person2-yolo26",
    "Roboflow_obstacle-yolo26",
]
```

```
In [2]: # 1. Visualización de la Distribución de Clases para el Dataset Maestro
df = plot_yolo_class_distribution(
    dataset_path,
    output_dir=output_dir,
    title="Distribución de Clases - Dataset Maestro Unificado",
    filename="01_Distribution_Dataset_Maestro_Unificado.png"
)
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/01_Distribution_Dataset_Maestro_Unificado.png.png



--- Distribución de Clases (YOLO) ---

Class	Count
obstacle	7470
door	4724
person	4215

```
| person | 4215 |
| stair  | 2889 |
| dog    | 1256 |
```

 Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/01_Distribution_Dataset_Maestro_Unificado.png.csv

Paso 2: Análisis Técnico del Dataset

Antes de analizar el contenido semántico del dataset, es fundamental verificar la calidad técnica de los datos a nivel de archivos e imágenes.

Dataset: `dataset_maestro_unificado` (dataset unificado, sin división en splits train/valid/test).

Objetivos:

1. **Analizar resoluciones:** Verificar consistencia de dimensiones de imágenes.
2. **Sanity checks de integridad:**
 - Archivos corruptos o ilegibles
 - Formatos incorrectos (RGBA, grayscale cuando se espera RGB)
 - Duplicados exactos dentro del dataset (contamination)
3. **Estadísticas de píxeles:** Calcular **mean y std por canal RGB** para normalización del modelo.
4. **Distribución de intensidad:** Analizar histogramas RGB para identificar necesidades de augmentation (brightness, contrast).

Impacto en el entrenamiento:

- Imágenes con resoluciones inconsistentes requieren redimensionamiento uniforme.
- Duplicados pueden causar overfitting artificial.
- Channel statistics son **críticas** para la normalización en PyTorch/TensorFlow.

```
In [3]: # Cargar dataset YOLO como objeto COCO
coco, img_dir = load_yolo_as_coco(dataset_path)
splits = {'all': coco}
img_dir_map = {'all': img_dir}
print(f"✅ Dataset unificado cargado: {len(coco.getImgIds())} imágenes

# Variables de interés para análisis de geometría y complejidad
target_cat_ids = coco.getCatIds()
id_to_name = {cat['id']: cat['name']} for cat in coco.loadCats(target_cat_ids)
print(f"📋 Clases encontradas: {list(id_to_name.values())}")

# Asignar colores automáticamente a cada clase
_color_pool = [
    (255, 0, 0),      # Rojo
    (0, 255, 0),      # Verde
    (0, 0, 255),      # Azul
    (255, 255, 0),     # Cyan/Amarillo
    (255, 0, 255),     # Magenta
    (0, 255, 255),     # Amarillo (BGR)
]
class_colors = {name: _color_pool[i % len(_color_pool)] for i, name in
print(f"🎨 Colores asignados: {class_colors}")
```

loading annotations into memory...

Done (t=0.03s)

creating index...

index created!

✅ Dataset YOLO cargado como COCO:

📁 Imágenes: 10386

📄 Anotaciones: 20554

📁 Categorías: ['obstacle', 'dog', 'person', 'stair', 'door']

✅ Dataset unificado cargado: 10386 imágenes, 20554 anotaciones


📁 Clases encontradas: ['obstacle', 'dog', 'person', 'stair', 'door']

📄 Colores asignados: {'obstacle': (255, 0, 0), 'dog': (0, 255, 0), 'person': (0, 0, 255), 'stair': (255, 255, 0), 'door': (255, 0, 255)}

In [4]: # 2. Visualizar distribución de intensidad de píxeles por canal RGB
plot_channel_histograms(splits, base_dir, sample_size=100, img_dir_map
output_dir=output_dir, filename='02_rgb_histog

📊 Generando histogramas de distribución de píxeles...

📁 Histogramas guardados: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/02_rgb_histograms.png



In [5]: # 3. Calcular estadísticas de canales RGB para normalización del model
df_pixel_stats = calculate_pixel_statistics(splits, base_dir, sample_s
img_dir_map=img_dir_map,
output_dir=output_dir, fil

📊 Calculando estadísticas de canales RGB...

ALL: RGB mean=[0.5431, 0.5231, 0.4982], std=[0.2607, 0.2629, 0.2727]

📁 Estadísticas guardadas: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/03_channel_stats.csv

In [6]: # 4. Detectar imágenes duplicadas dentro del dataset usando hash MD5
df_duplicates = detect_duplicates_across_splits(splits, base_dir, img
output_dir=output_dir,

display(df_duplicates.head())

Visualizar muestra de imágenes duplicadas
if len(df_duplicates) > 0:
dup_img_ids = df_duplicates['image_id'].unique().tolist()
sample_size = min(8, len(dup_img_ids))
sample_dup = random.sample(dup_img_ids, sample_size)
print(f"🔍 Mostrando {sample_size} imágenes duplicadas de {len(dup
visualize_sample(coco, target_cat_ids, id_to_name, class_colors, i
img_ids=sample_dup, output_dir=output_dir, filename=
else:
print("✅ No hay imágenes duplicadas para visualizar")

🔍 Calculando hashes MD5 de todas las imágenes...

⚠️ Se encontraron 743 imágenes duplicadas:

hash	split
0134a9c26b3c6c9e44fa16fd1caa7f19	['all', 'all']
01f50ded8d4f2d6d4d394040e1bd0d47	['all', 'all']
0245cca159882ac33f8b278290493054	['all', 'all']
031d2c16f5a73454664ecfab4c5ff70	['all', 'all']

042bcac43ceecdd0e01b9cb38637f9c0 | ['all', 'all']
05f6fb134e5cc31548414ce772acd318 | ['all', 'all']
061591781ed9f1b6b35d0533d07458ce | ['all', 'all']
06183bec031616229c4cb66ab27aa31e | ['all', 'all']
075af3b5114b016b39beb77cdf077dfe | ['all', 'all']
0776451cf88d32d61ca8922bb532e1f2 | ['all', 'all']
09fb19d7cb889ff893f306357c3e86b7 | ['all', 'all']
0a2437489639d6e62ceee48283ac745a | ['all', 'all']
0afbc45f94050e692bfd9a0e3379b5cb | ['all', 'all']
0bd033671d6b33d5a7bac40ca7f1dd54 | ['all', 'all']
0c357fcacf32adfdb642cbd769486d276 | ['all', 'all']
0c5febfb8eeaca02ed526371331d19e4d | ['all', 'all']
0ee7103785c7e2e2cd462b063b71bf69 | ['all', 'all']
0f25e6f2563122b948ba1c7963b3f37d | ['all', 'all']
0f3f0fe682c4500d0205e45db08dcbcb | ['all', 'all']
0f892cfe4fc9b3556ef0e0f65c48c9e7 | ['all', 'all']
0f919e69f18cdeed85dbe12e1e346e7a | ['all', 'all']
1057acd6dd61eac0dae6bb14f05e3bf5 | ['all', 'all']
12cc59f0753f23367ae8e55d8a0a1d87 | ['all', 'all']
1330d7388e89ff6521cf88fdb05bc836 | ['all', 'all']
13c1b852e8d7500225ff190feab65828 | ['all', 'all']
14cc91364a29cd128fec24e20d1c8f07 | ['all', 'all']
1588b93fd34ad05e2eb42ce2037553b8 | ['all', 'all']
15b402456ca33f9465017f59afe6db1c | ['all', 'all']
1739c9a0d0b8358431d964b67e61b48b | ['all', 'all']
175bc902fec17e958631aba461a5a425 | ['all', 'all']
17d241bad852e70f843c2a3922569077 | ['all', 'all']
1839e85707e5ff45a72378b4d47d0904 | ['all', 'all']
188480f402c8a9cbe52ee7784573bb47 | ['all', 'all']
19931b996a1c550974546dc2a6f36f6c | ['all', 'all']
1aa867dc3aa7b076fcf461798d4a78c4 | ['all', 'all']
1baf6842af97c55ac31369b93c3eeb2b | ['all', 'all']
1bc0620651df01ea1ae8931480bda1d8 | ['all', 'all']
1bc29d9f0c8ed6403856cbdf821ab783 | ['all', 'all']
1f641f69f0b1f458ae5d9681ec84ca80 | ['all', 'all']

1f1e1812a9e/20d4b821c2f91c132/f2 | ['all', 'all']
20848e774a28dc1800b70836ca879d09 | ['all', 'all']
21ed3dfdb4f0d83067dce8e8708493e0 | ['all', 'all']
2262422ad6422b01566829e94049b0d4 | ['all', 'all']
23c6a8029d36bd1b56ae9f41f03daf15 | ['all', 'all']
2432a192298a8eb9c7fa32f79d154723 | ['all', 'all']
250c87433d95ae0e5b2883f6dbc45e49 | ['all', 'all']
26181e5acb35957db1af5a98180486ec | ['all', 'all']
26bae7692d16e941048ce3670349570c | ['all', 'all']

26d0de7f0152373c7b512aa778ce41b9 | ['all', 'all']
27213f715315d5871010b66a7e388033 | ['all', 'all']
283606ab097adab1ef4334f275b90b0a | ['all', 'all']
296d39ba35d789e0106520ed404476ee | ['all', 'all']
2a4a759580fc077174ac316cbdf802ac | ['all', 'all']
2aa4d08a0de59491cdfdb22f9d117f07 | ['all', 'all']
2bf4f1e1fe31a85baa17496420646c5e | ['all', 'all']
2c4ccc952368f45ff76843bd8ba9351b | ['all', 'all']
2d17da946eed2b0651e5fcc50cb6db6b | ['all', 'all']
2d838d42f91f64a0d150bbde6865cfb3 | ['all', 'all']
2d8b28b241f3e4f4258ed7180b9495a9 | ['all', 'all']
2e0cc4b99c3f8e3da045feeea792e6b7 | ['all', 'all']
2f8d0013f0d2336ffe577f65f3f7d047 | ['all', 'all']
303c1e5e828c47102d44e54956f3c41c | ['all', 'all']
30e0ca420d380ab86112fdc146a829ed | ['all', 'all']
31a1a5e7207cd65f9c19990d300f2f4d | ['all', 'all']
321e510b9b67d9814863a121805c779f | ['all', 'all']
326b96177b8631fd1102d35a1241175c | ['all', 'all']
32ce1a3829dbdaea1d5b4d6f3cf27318 | ['all', 'all']
336d29664b3e621c2576c3c9dd9b1a9b | ['all', 'all']
339eaf7bd4d9e200577eaa8073526659 | ['all', 'all']
3474b992d5db85eface8512af3a58860 | ['all', 'all']
357c7b946fb21cf4f89d644d17c6711c | ['all', 'all']
36050380f2ede5b4bb6879041b4401ba | ['all', 'all']
363be8907760ecf81ac5099f225e8d76 | ['all', 'all']
369e06feae0ab1e0eaa4f2889057bc32 | ['all', 'all']

37a26c190946766a67e66a130530b8fe | ['all', 'all']
38a7cffa8c1b1c3c82ccef0f53d6dadd | ['all', 'all']
3bd249a5a7690cd0e15cf3d28a2b0702 | ['all', 'all']
3c31a263f253011ccb17caeff64e333a | ['all', 'all']
3c728b041d9d31d2835bbb9f374817f2 | ['all', 'all']
3ce2591c7f8894fc8b4cf6f2b9e9094b | ['all', 'all']
3d5a246d9449edd8dc8a7f77b5f1ba6e | ['all', 'all']
3de8a56781ad8741a4f025fa3d0fae84 | ['all', 'all']
3f1cc1425a10fa29f022ef4acc705ff1 | ['all', 'all']
409adc1fdf22da7a8687e6143eeb1868 | ['all', 'all']
40ce2bff40c1afe2743fc0fa73913db2 | ['all', 'all']
4169698449ccd10d34ef5dcd58a28c66 | ['all', 'all']
41c47ebd2dea74acf084b1e772e9946f | ['all', 'all']
423bb814a7050c5ad04d4384b367527e | ['all', 'all']
426ab6d253c176916cb75183581545e1 | ['all', 'all']
4330179c4ce5e7f1516043c24592976d | ['all', 'all']
444ada94fbd973c8740def4c78356724 | ['all', 'all']
44ad1eb7e42873f209ee9911fcd8c2ea | ['all', 'all']
45d71f2d35a7fc60cf872ea0b0e61da3 | ['all', 'all']
460c25868d526460c94484bccc170fc7 | ['all', 'all']
47d98df482b16f20f4c687e914c1e418 | ['all', 'all']
481ad1382e9b97a8e6c4223df4465d74 | ['all', 'all']
48544bb39d0544fb28682feb62dc38ca | ['all', 'all']
485de9d6819ef349ace6ff64051eb114 | ['all', 'all']
4a1f148c1a9c660aaf1b61343c02d9db | ['all', 'all']
4a2e2def55901a32983943f230884a75 | ['all', 'all']

4b25232b10aa48dfc9ac1dbb6effde3b | ['all', 'all']
4b5e8acc4527c3a3b0fc882b03074390 | ['all', 'all']
4b876bfdd8e17f823081c4223c50372f | ['all', 'all']
4bc33b157460a00b0295f3f1ffaaed6e | ['all', 'all']
4cedc14d9d6702eeb6062f844b3944b5 | ['all', 'all']
4d9e9ba40cf6bafa309f9fbb6bb423b4 | ['all', 'all']
4e91a38724e144885a094cf4f6321ede | ['all', 'all']
4ebfe5c7bf53a1b89b6ef340ddf8a02f | ['all', 'all']
505ah56f0cae70d972a9200d6cc0d65 | ['all', 'all']

```
5179ba1a6d47c6676d046504558d0910 | ['all', 'all']
5204093bc6b440cf7fb1f1b56b1ff313 | ['all', 'all']
5272644b7318229c59efa9bbe29ec151 | ['all', 'all']
52e9df241736a9ba3c93af64c7f1515e | ['all', 'all']
531245db70c85c0f043cbce3ff0bbce8 | ['all', 'all']
53ea4bd25ade61d3a06d7e5d0e18d922 | ['all', 'all']
56679b634d1d6119ee56d809b6574fc8 | ['all', 'all']
56a7247ef40c228055b7a54f965b8b3a | ['all', 'all']
5871f196e0c3f6f67fd2d2b92bda1a7c | ['all', 'all']
58864b9f9d2eb25c8c4ad3a81c805d6c | ['all', 'all']
58cf8f78fa9cee8ffa8b369fa1c197cb | ['all', 'all']
5a7731e09cdd31b6dd22161dc92d387f | ['all', 'all']
5ae0faa1f6902761cb14564cd43c0cb7 | ['all', 'all']
5afa9bb725c0f944ad1e4158badb7eb1 | ['all', 'all']
5b7a1801cb9e07b1780e413aff8e8c83 | ['all', 'all']
5b84256cfe6d9e2774b6a28bee1acd0f | ['all', 'all']
5c6bcd186ac740f1ad39dda300f0aee1 | ['all', 'all']

5d8a4e4ef0e321dd718e47b3361da4d6 | ['all', 'all']
5df17f108c8c92e011dc67766a04dde0 | ['all', 'all']
5e24983b0398297f893476de5070735e | ['all', 'all']
5ea066ee7a88fb2b2851717876ea38ff | ['all', 'all']
5f678a7da1c3e2459be4c929e4333458 | ['all', 'all']
628507fda2cc75b342456aa902352e5f | ['all', 'all']
6349eaa7cab91334157d92491e6d758a | ['all', 'all']
63d696e7af764bfb218b09fbfead627d | ['all', 'all']
648f63dbfcef82dc6b2113828718bcb8 | ['all', 'all']
6503045ba22846a94752a2fe1b79590e | ['all', 'all']
660a508f600cdb560cda9e1dd9f0b030 | ['all', 'all']
661fea14d7f97bf3ac9da87fed732d68 | ['all', 'all']
66207635a861aa4cfd35db834ed37a1b | ['all', 'all']
66858ce1eef21f15be2ec1b1f32f47d6 | ['all', 'all']
66ee49d00ce7c006dce4a247539629d8 | ['all', 'all']
670d0da03e7ff40d0932beb87432bcad | ['all', 'all']
672f7bc5f3514401a13edd7aba5521e5 | ['all', 'all']
```

b8345caed122/c/d8ca104//5t583a8a		['all', 'all']
69658aeab1805fe2a0dc9fcc9ab6c8f5		['all', 'all']
69f22e476c15244751df87c125c3eadb		['all', 'all']
6a5f170b7e1f2a9db6ae4d41c6c7399		['all', 'all']
6aa90db701eb0c036b340a9c4b1a4530		['all', 'all']
6ab9ac32027ebb3d67771a741abdbd9a		['all', 'all']
6bd335352fb1a5ec1d593392a54243a8		['all', 'all']
6d613ce7cba3ffca4c79112ef759e0e1		['all', 'all']
6d8b6f7b382f47e0556582e58cc543a9		['all', 'all']
6ed81c7ec9545880e9d118fd757ec882		['all', 'all']
7074b9335ec5529da853b655ae0ba791		['all', 'all']
71e6eafb8a2900ebaa0a9c829133c8d6		['all', 'all']
71f5950889d8a501d40796e7873c910c		['all', 'all']
728e0e009949c36c3ffed0c4420f8300		['all', 'all']
736aacfc8f737acfd575041aef1897		['all', 'all']
7376ec89c1e22ee9a69d0fc4029be1c0		['all', 'all']
73a21e5fd4d1f7d3f2022778ee473317		['all', 'all']
746250cd769cfbfd09a1afd7d03a42ad		['all', 'all']
74b50c93f211f34573c414d68d368e6f		['all', 'all']
755b4a665b596492065952a36d3e2068		['all', 'all']
7561ce0cf6d58ff16c763d182b34f5e3		['all', 'all']
7660eb4cc52f3675f63bd6aa3543e145		['all', 'all']
76980c882fb5416f62dd898ba524a689		['all', 'all']
789da3fb380351c880f39ac8f0598f63		['all', 'all']
795671389bb8f486983acdc254efc202		['all', 'all']
799fd208a10acba8c8a7c375d1a8f5ca		['all', 'all']
7a3abdfa2ebcfbb9cff49d8848ec8d9e		['all', 'all']
7aea59c192144b5a0ec6052a41e25a77		['all', 'all']
7b957d3e6e21b589b244a1042dc51bc8		['all', 'all']
7c6a8274a74b6c237141a44dd004dcbe		['all', 'all']
7edadea776a564b07c866083c4d756b8		['all', 'all']
7f299db20ba5f194f1d0f58786250b1b		['all', 'all']
7f2f4e5d2af20377369371c2e4dc9fe2		['all', 'all']
7febd087bdd1aa10a7b774be8aaac1f9		['all', 'all']
8126d911df21dfeb7dcb088806b0b9b1		['all', 'all']

8140b3c0a9d22c5782c91462acae8c64 | ['all', 'all']
816448d81e1067c9201ed5e320f50a56 | ['all', 'all']
81f0856f5854b47367aeee982785e1ae | ['all', 'all']
823b6ac47fe9b4caafb395ce961e66c | ['all', 'all']
83183e0c96746c3a80a7a817ca5e0763 | ['all', 'all']
845c861ad0b5d1f0135f9b4550fe7b67 | ['all', 'all']
8650d7e8d6f9d672b638301f8a7fd050 | ['all', 'all']
878ee887ec43beac526df0b0e01e0274 | ['all', 'all']
8816faa047556daf9bc10a25073f779a | ['all', 'all']
8a36dc11b9639bf6afcd9910013ed2a9 | ['all', 'all']
8a84208cb0bebab2ce6799bce23d112a | ['all', 'all', 'all']
8c02b17f34633c42316fd80f35e8fbdd | ['all', 'all']
8c8a7835acd0cfe645ecb8b342ab627f | ['all', 'all']
8cd56bd9c4a920a5a32aca858d580618 | ['all', 'all']
8db93b0ed5f068d8503a887134f9bca1 | ['all', 'all']
8e3eb1384e4393a036fe48460eae1b0 | ['all', 'all']
8e8ae62366f5c0ef1d91901b3f06b668 | ['all', 'all']
8f1608ba20a0c5c23e354f51e65df423 | ['all', 'all']
8f16a4bc15d1878d44df1170a7375f09 | ['all', 'all']
8fe4cf6099f0dfce892f2c962f38787d | ['all', 'all']
91f6254b69b06b98966c26cd484024b1 | ['all', 'all']
92b7198949be175c35a8720aa3ae6fb9 | ['all', 'all']
92c7bdfdc182d160481e71cc942385d | ['all', 'all']
95a9564139a1a1dbd73ef752ce0dc03e | ['all', 'all']
964af415f28322c3d9e6a8b70cb91389 | ['all', 'all']
96c93acd3b32c612d199f657c868c36b | ['all', 'all']

9753dd54aeab156bf857e0737c11e66d | ['all', 'all']
976f334a54124c98475de2fd9f1d2e37 | ['all', 'all']
98c605fd4584cd6516a5dea8392f36f9 | ['all', 'all']
98d1aadfce81f8db4c9659a6ad3d67e6 | ['all', 'all']
98f250d4ec70bd9b36ee15b2f598d326 | ['all', 'all']
998cab8285bf4478ea0f19d485fd89c3 | ['all', 'all']
99dc89d61f10eb8f60676aaf97cce106 | ['all', 'all']
99ebbb99bba8f1871129682b66db07f0 | ['all', 'all']
99f606797155cdhh57237ch44158h849 | ['all', 'all']

9a87281c43b780dd7e508bbe93ade4de	['all', 'all']
9c81e579cecd12da3f0ec447f889014	['all', 'all']
9d627cf65005ef16dd71c6749ef4d692	['all', 'all']
9e91cd7d83c2ab345b70320cb4d94e33	['all', 'all']
9f34ef202d606de9374db60a84205178	['all', 'all']
9f4e213469bd7ce8af5ff665b775418b	['all', 'all']
a00e3c2b4ab071dbb5c1317f7b75168b	['all', 'all']
a010a797951a33dd90b63cf005ffe8bf	['all', 'all']
a0441635e2b2cbdbebf7596752b0088e	['all', 'all']
a0a3f6760c285a939dc80d2eafabb329	['all', 'all']
a0bcef8be7cfff5d627321c574900adbf	['all', 'all']
a1d404b5c9980be3f2471a839ec34fe9	['all', 'all']
a1d86302c939c76f5513a401867ea736	['all', 'all']
a3c74cd4e0f3ef46f8fcaa50605e988a	['all', 'all']
a4052d9bdbba454380469844289669b9	['all', 'all']
a4967048240e49af6c06d17c97d0123f	['all', 'all']
a4bc4abc63c76694e144baf115faf55a	['all', 'all']
a5b1590a04aee2ab567db2279887912c	['all', 'all']
a84797aa4c18d2feba2b3a37e86b9f19	['all', 'all']
a8590b6e9b36ed3ec2e3b01e0fd6f93f	['all', 'all']
aa87e77f49f15f6db627b73e7d279cb8	['all', 'all']
aaff97cc7243db73e9b248ad5e0a286c	['all', 'all']
abf442f81ead7b3728e1c241541091f0	['all', 'all']
ac25a7ec5ea587f6d829932a9a0cb0b3	['all', 'all']
ac9cad36a8d33962ff2e88ef32ed5634	['all', 'all']
aead9b22803a5ee808eaa9dd4273ef79	['all', 'all']
af0ecb0e8de7606854b7484b448e6968	['all', 'all']
b12e519dd040491b0c51291ff7a7fe9d	['all', 'all']
b20e3c5039c695205023c782117faae2	['all', 'all']
b23c5b8d34e557e11af15fce21aefa99	['all', 'all']
b2596c4720c494d1497a9caa426f5a41	['all', 'all']
b2bb6d2cc2509fb955a5cfd1275b600f	['all', 'all']
b36d3404bf1d77415be9e25eee21414e	['all', 'all']
b7eba4e4f684ff9a60170f3245872e42	['all', 'all']

b98b03bc1001505bac10b81110dde1b		['all', 'all']
b9f71cc166c78b76ce54632847c45894		['all', 'all']
ba3cffa5d9e6078907517d50ad5700ab		['all', 'all']
ba4577756e8f9e3deb1d0c920cf2f8d7		['all', 'all']
bb5d1d065bc2e5f950c0a3289225a5b7		['all', 'all']
bbc25462204fed46f90fa486e99ce406		['all', 'all', 'all', 'all', 'all', 'all']
bbe8d83398f44e9eb378a89f7e86a4c8		['all', 'all']
bc015b1126bfb590ab2fc20659fc89f0		['all', 'all']
bcc301b42df0209036f0ba589575ae9a		['all', 'all']
bd0c9ba95c45ca44649a14c8366c2847		['all', 'all']
bd5d4b08dcbbff8a701edad1a797faa25		['all', 'all']
be8bceef3063983d2f5bb88c0605999		['all', 'all']
bea769fd4b48caf2114a0c2a0848f7d3		['all', 'all']
bf4ee2c5b1312457b48521ae7119bdfe		['all', 'all']
bf7c7d5bbe6c1533faf2b9e69e3967d0		['all', 'all']
c311bc3bc70a5df92e602e045dc75fdd		['all', 'all']
c31c5750925e8e6a81aa73551f10d7c8		['all', 'all']
c36725dda6aa12bf43a9d018c304d7c0		['all', 'all']
c3eb2143b6295f10a7c2209d42e88f2e		['all', 'all']
c4238d7a7becbf3675b98c873889a804		['all', 'all']
c529643a0393a99d02cf24bf59bf5f73		['all', 'all']
c576ad5bdd11535ee15fd887281d5d9d		['all', 'all']
c5c0ecf61933b8d265940491d15f2b94		['all', 'all']
c5d3ee600a243624ba6101ecaaa7edd4		['all', 'all', 'all', 'all']
c650cf06a5ecc4a8e8dc203a4eaf9649		['all', 'all']
c7081f911e94b37fd1694c7ae57c513b		['all', 'all']
c729f562210f86e9ddcf3bbc6a0f0b79		['all', 'all']
c749f461107da3aa04cd4588b5fdf0b9		['all', 'all']
c81c208b41c24bc017f576bca55e1f43		['all', 'all']
c828540b0bcbfe9faa914ac4080ad778		['all', 'all']
c895741c76026534a0db067b0bd11b4f		['all', 'all']
c9840a3149363abebab0d0eec065f4c2		['all', 'all']
ca7acc75abfd0535e9c588c7575a317a		['all', 'all']
cae277207bb03d8253d3b3f3c37711d7		['all', 'all']
cb2592d1ff611f775a99dc3b7d22143		['all', 'all']

```

| cba8429b25fa1e8e7c63942ac696e534 | ['all', 'all']
| cd010125b66776a9e69bc58c4360aeec | ['all', 'all']
| cd3c3d4c7b52923e9e0d6be88c57a88f | ['all', 'all']
| cd50b5d80e9cc2efbdad4c80e075ed5d | ['all', 'all']
| cdc2afed7196d1f85b92c4d05a92a261 | ['all', 'all']
| cf9a400ee0fd4a67b71380652d169cb6 | ['all', 'all']
| cfc6310445e2427b61e88cce4bc5e64c | ['all', 'all']
| d0180d109146ace4290ca012ec92da0b | ['all', 'all']
| d1153cb438abd66ec2d45bd81c626ff0 | ['all', 'all']
| d218b517bab36c1df7257a13e2fc3cc0 | ['all', 'all']
| d480e8838700fab5717ef59567d4126e | ['all', 'all']
| d4ce2ae2ff69a12fed7ace6b1ca3a03f | ['all', 'all']
| d4cffffeb84263c587d2e5fa2a762b14b | ['all', 'all']
| d4d5cb340a31db0505ef93f198d968de | ['all', 'all']
| d64edb905071972443ec3e40b5554a25 | ['all', 'all', 'all', 'all']
| d790867a271dec642974416b0d845a12 | ['all', 'all']
| d7f889c39316b60f863f9f97f717a239 | ['all', 'all']
| d9e24e11de8a6b7a44d904afbef2579c | ['all', 'all']
| da7049d6d4c7e14f70c1cda645379a5e | ['all', 'all']
| db4c647c985ac7ea88a78db5a515530b | ['all', 'all']
| dbd8325d6a6680473535865dc41ecb8d | ['all', 'all']
| dc2872463b9ec0fc091f7ff93f496eef | ['all', 'all']
| dc2b995bf590a244dda06e8bea354024 | ['all', 'all']
| dcd47b7fa474039ed2f146873d30d223 | ['all', 'all']
| dd5a2590887b1b039e811a10226b6a5a | ['all', 'all']
| de62ac59580a5a16d7758b66d05a36fa | ['all', 'all']

| deb5c92874917ef5c50b5180bf9c1427 | ['all', 'all']
| dedceb089af1c23db5d4bd080aab38a7 | ['all', 'all']
| e0ffd704ac6c9d5cd3ce44b828d20c00 | ['all', 'all']
| e104609d01461b31054888b56471f0eb | ['all', 'all']
| e15d581d5d8a7e64449dd24e3c90cd07 | ['all', 'all']
| e2c6035764b88831854d71fbc03d4f46 | ['all', 'all']
| e3d9dbe7873118ff0efd66b5caa7f405 | ['all', 'all']
| e409c63c668d739c0ec19035a4b4faed | ['all', 'all']
| e4a8046cfc3894fca701d033fcah2ad7c | ['all', 'all']

```

```
e5cd3cfbf97c251a63b1789d6dd8c15a | ['all', 'all']
e61d00e28ba53e7df058f7dff426fd7b | ['all', 'all']
e640315aa85473228f2d9abb2e4bf3bb | ['all', 'all']
e66c790194107a9ead178a79c450d447 | ['all', 'all']
e68c7006fb831250d535c8da70057674 | ['all', 'all']
e6c9974440599df1fced7e3e11133866 | ['all', 'all']
e6f63c4e1b351243923e9beb76f06d71 | ['all', 'all']
e6fffb0d1598a896bdf466d7bbec5a19 | ['all', 'all']
e70c9d0e922ce62982547c677e1873d7 | ['all', 'all']
e746983c8514c9c66cecbc735faacf60 | ['all', 'all']
e7be66d687f09c4dea89b8f88da3060a | ['all', 'all']
e7ef25b734be9b8e30ce4ca04fafd677 | ['all', 'all']
e7f81ee9fc2fc4d6ba6aebb2b2b6d8c5 | ['all', 'all']
e9a748af8b40f61ff486e0b06f7c5b47 | ['all', 'all']
ea4ccda84187b3989924a65c38a5effb | ['all', 'all']
eafeb68a6ba62ff32c50278fd488b1fe | ['all', 'all']
eda50c3299f00c1a7180bab552926837 | ['all', 'all']

ee5574986e18f86b29a21b71f4b45c4f | ['all', 'all']
eee82d62ac380e0b1069303542f7e1af | ['all', 'all']
ef12504111d70c6923d9b2ff0ba1439f | ['all', 'all']
effca76faef8d7ac9443a722fb8e1cbd | ['all', 'all']
f0c4183aca3ef2610d4cd52a4874a5bb | ['all', 'all']
f0d5e21f027d39e73af00f1633a4bb08 | ['all', 'all']
f0e2e281c57385860b78108310a43b65 | ['all', 'all']
f138f9c56fd09551756ad637536906da | ['all', 'all']
f1957cbcc879cf596b5dee51c9a9e8e3 | ['all', 'all']
f199e487a8dd95809fabe5180a70b3ad | ['all', 'all']
f1c9ceebe94119d938892af07632e6ff | ['all', 'all']
f22a257a01227d9347708da2c3d7ac39 | ['all', 'all']
f2604f929e4b70d24794c7be59c50d3a | ['all', 'all']
f27f4e7fe0552d37770fa9d22b7fa8d5 | ['all', 'all']
f2d986aba95a5c20cd3ad5347794caf8 | ['all', 'all']
f335f6fbdedb945887fe0bb89afeb033 | ['all', 'all']
f52135e1a18224bed363f2014a409eee | ['all', 'all']
```

f6013b0b020f85ec9bd0948e85be3e59 | ['all', 'all']

f63bf4acf9067e8b5b0ec75829b9be4e | ['all', 'all']

f6ae3f9e73c0361c70573842d30bddf1 | ['all', 'all']

f778a34ebadee5e63bade7dc7417c96a | ['all', 'all']

f7e1ec9b56ca816b24f557c774358e03 | ['all', 'all']

f835663e9b1d94cbc36d2e123d4e0e44 | ['all', 'all']

f8b492be816134811d65695b4f31d589 | ['all', 'all']

fa7e2fac7cd9d128accf567e06125df1 | ['all', 'all']

fae234190ff9ab7e3e91f6e2c54b83da | ['all', 'all']

fb3848c5c22bab530ce9bd8a34ef8446 | ['all', 'all']

fb5e09bed8f2ea3b9ce40a3dfdc1b4ac | ['all', 'all']

fbdb0856b6bbfe4f0c86e903c8b1901f7 | ['all', 'all']

fbf28cf166edbba1d5ff6582d6a5abe7 | ['all', 'all']

fd98048c05000b2f7856db8f0a2bad4e | ['all', 'all']

fed3efa176ee14ac2f43e66d393b4fbc | ['all', 'all']


ffa5fe5324dda59f8d79b639d9722ab6 | ['all', 'all']

Reporte de duplicados guardado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/img_005527.jpg.csv

	hash	split	image_id	filename	duplicat
0	7b957d3e6e21b589b244a1042dc51bc8	all	259	img_000259.jpg	
1	7b957d3e6e21b589b244a1042dc51bc8	all	4390	img_004390.jpg	
2	8db93b0ed5f068d8503a887134f9bca1	all	260	img_000260.jpg	
3	8db93b0ed5f068d8503a887134f9bca1	all	4391	img_004391.jpg	
4	2d8b28b241f3e4f4258ed7180b9495a9	all	282	img_000282.jpg	

Mostrando 8 imágenes duplicadas de 743 encontradas

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/04b_duplicate_samples.png



```
In [7]: # 5. Verificar integridad de archivos de imagen
df_integrity = check_file_integrity(splits, base_dir, img_dir_map=img_dir_map,
                                     output_dir=output_dir, filename='0
```

✓ Verificación de Integridad: SIN PROBLEMAS
Todas las imágenes son válidas y legibles (RGB)


```
In [8]: # 6. Extraer dimensiones de todas las imágenes
df_dimensions = get_image_dimensions(splits)
plot_resolution_scatter(df_dimensions, output_dir=output_dir, filename
```

/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/src/utils_eda.py:1180: FutureWarning: DataFrameGroupBy.apply operated on the grouping columns. This behavior is deprecated, and in a future version of pandas the grouping columns will be excluded from the operation. Either pass `include\_groups=False` to exclude the groupings or explicitly select the grouping columns after groupby to silence this warning.

```
unique_resolutions = df_dims.groupby('split').apply(
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/06_resolution_scatter.png

Tabla de resoluciones guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/06_resolution_scatter_table.csv



Paso 3: Análisis de Distribución de Clases

En esta etapa se decide qué clases se conservan basándose en su representatividad y relevancia estadística.


- **Conteo de Instancias por Categoría:**
 - **Objetivo:** Identificar clases "minoritarias" que el modelo no aprenderá bien.
- **Imágenes por Categoría vs. Objetos por Categoría:**
 - **Objetivo:** Determinar si una clase está bien distribuida en el dataset o si aparece concentrada en pocas imágenes.
- **Matriz de Co-ocurrencia:**
 - **Objetivo:** Analizar qué objetos aparecen juntos para entender el contexto (ej. la relación entre "Mesa" y "Silla").

```
In [9]: # Usar dataset unificado completo para análisis de clases
print(f"✓ Usando dataset unificado para análisis de clases: {len(coco
```

✓ Usando dataset unificado para análisis de clases: 10386 imágenes

```
In [10]: # 7. Obtener categorías y conteos
cat_ids = [cat['id'] for cat in coco.loadCats(coco.getCatIds())]
df_counts = get_category_distribution(coco)
plot_category_distribution(df_counts, scale_type='linear', palette='ma
                           output_dir=output_dir, filename='07_category
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/07_category_distribution.png




--- Tabla de Distribución ---

Category	Count
obstacle	7470
door	4724
person	4215
stair	2889
dog	1256

Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/07_category_distribution.csv

```
In [11]: # 8. Obtener Densidad de Imágenes VS. Objetos
df_density, active_cat_ids = calculate_image_object_density(coco, cat
plot_image_object_density(df_density, palette='magma',
                           output_dir=output_dir, filename='08_image_obj
```


Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/08_image_object_density.png



```
In [12]: # 9. Obtener Matriz de Co-ocurrencia
co_occurrence_matrix, cat_labels = calculate_cooccurrence_matrix(coco,
plot_cooccurrence_matrix(co_occurrence_matrix, cat_labels, cmap='YlGnB',
output_dir=output_dir, filename='09_cooccurren
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/09_cooccurrence_matrix.png

Matriz guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/09_cooccurrence_matrix.csv




```
In [13]: # 10. Calcular ratio Objetos/Imagen por categoría
df_ratio = calculate_and_plot_density_ratio(df_density, palette='magma',
output_dir=output_dir, fil
```

--- Ratio de Densidad (Promedio de objetos por imagen donde aparece la clase) ---

Category	Images	Objects	Ratio
person	936	4215	4.5032
dog	436	1256	2.8807
obstacle	3092	7470	2.4159
door	3698	4724	1.2774
stair	2559	2889	1.129

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/10_density_ratio.png

Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/10_density_ratio.csv



Paso 4: Análisis Geométrico de Bounding Boxes

- **Distribución de Tamaños (Área):**
 - **Objetivo:** Clasificar objetos en **Pequeños, Medianos y Grandes** (Estándar COCO).
- **Relación de Aspecto (Aspect Ratio):**
 - **Objetivo:** Graficar ancho vs. alto.
- **Posición Espacial (Heatmap):**
 - **Objetivo:** Mapa de calor de los centros de las cajas.
- **Optimización de Anchors:**
 - **Objetivo:** Calcular anchors óptimos usando K-Means clustering sobre dimensiones de bboxes.

```
In [14]: # 11. Extraer geometría usando función modular
df_geo = extract_bbox_geometry(coco, target_cat_ids,
                               output_dir=output_dir, filename='11_bbo
```

Geometría de Bounding Boxes extraída: 20554 anotaciones

Category	Count	Area_mean	Area_median	Ratio_mean	Ratio_std
dog	1256	64625	35662.5	4.54	11.48
door	4724	89271.7	78081.5	0.57	4.35
obstacle	7470	52906.9	27156	2.07	9.33
person	4215	31314.2	15867	1.28	5.25
stair	2889	188734	166793	1.17	0.69


Geometría guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/11_bbox_geometry.csv

Resumen guardado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/11_bbox_geometry_summary.csv

```
In [15]: # 12. Visualizar la Distribución de Tamaños COCO
plot_size_distribution(df_geo, colormap='viridis',
                      output_dir=output_dir, filename='12_size_distribu
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/12_size_distribution.png
<Figure size 1000x600 with 0 Axes>



--- Porcentaje de Tamaños por Clase ---

Category	Large (>96²)	Medium	Small (<32²)
dog	89.65	9.63	0.72
door	97.42	2.33	0.25
obstacle	79.83	18.96	1.22
person	66.38	30.34	3.27
stair	96.85	2.98	0.17

Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/12_size_distribution_percentages.csv


```
In [16]: # 13. Visualizar el Aspect Ratio
plot_aspect_ratio(df_geo, palette='magma',
                  output_dir=output_dir, filename='13_aspect_ratio', fig
```


/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/src/utils_eda.py:517: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df_geo, x='Category', y='Ratio', palette=palette)
```


Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/13_aspect_ratio.png





In [17]: `# 14. Visualizar el Heatmap Espacial
plot_spatial_heatmap(df_geo, cmap='magma',
output_dir=output_dir, filename='14_spatial_heatmap`

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/14_spatial_heatmap.png



In [18]: `# 15. Extraer dimensiones normalizadas de todos los bboxes
bbox_dims = extract_bbox_dimensions(coco, target_cat_ids)

print(f"\n📦 Total de bounding boxes extraídos: {len(bbox_dims)}")
print(f" Dimensiones: ancho y alto normalizados [0,1]")`

📦 Total de bounding boxes extraídos: 20554
Dimensiones: ancho y alto normalizados [0,1]


In [19]: `# 16. Calcular y visualizar anchors óptimos usando K-Means
optimal_anchors = kmeans_anchor_optimization(bbox_dims, n_anchors=10,
plot_anchor_clusters(bbox_dims, optimal_anchors, output_dir=output_dir`

```
filename='16_anchor_clusters', title='Optimización
```

Ejecutando K-Means con 10 clusters sobre 20554 bboxes...

✓ Anchors optimizados calculados

Visualización de anchors guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/16_anchor_clusters.png



```
In [20]: # 17. Exportar configuración YAML con Anchors optimizados
export_yolo_anchors(optimal_anchors, img_size=640, output_dir=output_dir,
                    filename='17_yolo_anchors')
```

Configuración de Anchors para YOLO:

Imagen: 640x640

Anchors P3/8 (pequeños): [[76, 91], [110, 226], [233, 108]]

Anchors P4/16 (medianos): [[118, 392], [496, 100], [145, 553]]

Anchors P5/32 (grandes): [[294, 311], [328, 539], [525, 362], [584, 592]]

Configuración YAML guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/17_yolo_anchors.yaml

Usar en modelo: copiar anchors a tu archivo de configuración YOLO

Paso 5: Complejidad de la Escena

Determina la carga computacional y la dificultad técnica del entrenamiento.


- **Objetos por Imagen (Densidad):**
 - **Objetivo:** Histograma de cantidad de objetos por foto.

- **Impacto:** Imágenes vacías ayudan a reducir falsos positivos; imágenes muy densas requieren más memoria GPU.
- **Superposición (Oclusión):**
 - **Objetivo:** Calcular el **IoU (Intersection over Union)** entre cajas.
 - **Impacto:** Si hay mucha superposición, se requiere un ajuste fino del *Non-Maximum Suppression (NMS)*.

```
In [21]: # 17. Visualizar Histograma de Densidad
img_ids = coco.getImgIds()
density_counts, ious = calculate_density_and_iou(coco, target_cat_ids)
plot_density_histogram(density_counts, color='orange',
                      output_dir=output_dir, filename='17_density_histo
```


Procesando imágenes para calcular IoU y Densidad...


Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/17_density_histogram.png



```
In [22]: # 18. Visualizar Histograma de Oclusión (IoU)
plot_iou_histogram(ious, color='purple',
                  output_dir=output_dir, filename='18_iou_histogram', t
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/18_iou_histogram.png





```
In [23]: # 19. Resumen numérico de Densidad
print_density_stats(img_ids, density_counts,
                    output_dir=output_dir, filename='19_density_stats')
```

Total Imágenes Analizadas: 10386
 Imágenes Vacías (Background): 35
 Promedio de objetos por imagen: 1.98
 Máximo de objetos en una imagen: 96
 📁 Estadísticas guardadas: /Users/admin/Documents/TFM_UNIR/01_ING_DATO
 S/Reports/19_density_stats.csv

Paso 6: Inspección Visual Cualitativa (Sanity Check)

Validación manual para asegurar la calidad de la información.

1. **Visualización Randomizada:** Renderizar imágenes con sus etiquetas para confirmar la coherencia de las clases elegidas.
2. **Verificación de "Ruido":** Identificar errores de etiquetado, como cajas que cubren toda la imagen o que son de tamaño minúsculo.


```
In [37]: # 20. Visualizar Sample de Imágenes
visualize_sample(coco, target_cat_ids, id_to_name, class_colors, img_d
                output_dir=output_dir, filename='20_visual_sample_1', t
```

📁 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report
 s/20_visual_sample_1.png



```
In [25]: # 21. Visualizar Sample de Imágenes
visualize_sample(coco, target_cat_ids, id_to_name, class_colors, img_d
                output_dir=output_dir, filename='21_visual_sample_2', t
```

📁 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report
 s/21_visual_sample_2.png



```
In [26]: # 22. Visualizar Sample de Imágenes
visualize_sample(coco, target_cat_ids, id_to_name, class_colors, img_dir=output_dir, filename='22_visual_sample_3', t

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report
s/22_visual_sample_3.png
```



```
In [27]: # 23. Detectar anomalías
suspect_tiny, suspect_huge = detect_anomalies(coco, target_cat_ids, id_to_name, class_colors, img_dir=output_dir, filename='23_detect_anomalías', t
```

--- Iniciando búsqueda de anomalías ---

Resultados del escaneo:

⚠ Cajas Minúsculas (<15x15px): 36

	img_id	category	bbox	area
0	1420	obstacle	[639, 222, 1, 186]	186
1	4403	obstacle	[291, 631, 22, 9]	198
2	4469	obstacle	[222, 639, 88, 1]	88
3	4472	obstacle	[47, 639, 144, 1]	144
4	4489	obstacle	[358, 639, 63, 1]	63

⚠ Cajas Gigantes (>95.0% imagen): 366

	img_id	category	bbox	ratio
0	920	obstacle	[4, 0, 635, 634]	0.982886
1	939	obstacle	[0, 6, 639, 634]	0.989077
2	1010	obstacle	[2, 14, 638, 625]	0.973511

3	1019	obstacle	[0, 3, 640, 635]	0.992188
4	1033	obstacle	[10, 7, 628, 633]	0.970518

 Cajas minúsculas guardadas: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/23_anomalies_tiny.csv


 Cajas gigantes guardadas: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/23_anomalies_huge.csv

```
In [28]: # 24. Visualizar imágenes anómalas de cajas minúsculas
if len(suspect_tiny) > 0:
    print("\n Ejemplos de imágenes anómalas: con cajas minúsculas")
    unique_tiny_ids = list(set([s['img_id'] for s in suspect_tiny]))
    sample_size = min(8, len(unique_tiny_ids)) # Máximo 8 imágenes en
    sample_tiny = random.sample(unique_tiny_ids, sample_size)

    # Usar grilla de visualize_sample para mostrar múltiples imágenes
    visualize_sample(coco, target_cat_ids, id_to_name, class_colors, i
                    img_ids=sample_tiny, output_dir=output_dir, filena
```

Ejemplos de imágenes anómalas: con cajas minúsculas

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/24_anomaly_tiny.png




```
In [29]: # 25. Visualizar imágenes anómalas con cajas gigantes
if len(suspect_huge) > 0:
    print("\n Ejemplos de imágenes anómalas: con cajas gigantes")
    unique_huge_ids = list(set([s['img_id'] for s in suspect_huge]))
    sample_size = min(8, len(unique_huge_ids)) # Máximo 8 imágenes en
    sample_huge = random.sample(unique_huge_ids, sample_size)

    # Usar grilla de visualize_sample para mostrar múltiples imágenes
    visualize_sample(coco, target_cat_ids, id_to_name, class_colors, i
                    img_ids=sample_huge, output_dir=output_dir, filena
```

Ejemplos de imágenes anómalas: con cajas gigantes

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/25_anomaly_huge.png





Síntesis del EDA: Dataset Indoor Obstacle Detection

La siguiente tabla resume los hallazgos críticos del Análisis Exploratorio de Datos, sus implicaciones técnicas para un sistema de navegación robótica basado en ESP32-S3 (TinyML) y las acciones correctivas definidas.

Paso del EDA	Tarea Realizada	Hallazgos Clave	Implicaciones Técnicas	Acción a realizar en Preprocesado	A c E
Paso 1	#1. Visualización de la Distribución de Clases para el Dataset Maestro Unificado	5 clases, 20,554 anotaciones en 10,386 imágenes. Desbalance significativo: obstacle (36.3%, 7,470) domina; dog (6.1%, 1,256) es la clase minoritaria. Ratio max/min = 5.95:1.	El modelo sesgará predicciones hacia obstacle y subdetectará dog. Para navegación robótica, dog (agente biológico impredecible) y stair (riesgo estructural) requieren recall alto pese a menor representación.	Aplicar augmentation selectiva a clases minoritarias (dog, stair). Considerar oversampling estratégico de dog.	U ir p la Ir L d N p e d
Paso 2	#2. Visualizar distribución de intensidad de píxeles por canal RGB	Distribución bimodal en los 3 canales con picos en extremos bajos (~0-50) y altos (~230-255). Canal Blue ligeramente inferior. Pico pronunciado en 255 indica sobreexposición parcial.	La bimodalidad refleja mezcla de escenas oscuras (pasillos, interiores con poca luz) y bien iluminadas. Alta varianza de iluminación es positiva para generalización del modelo en entornos interiores reales.	Aplicar augmentation de brillo y contraste para ampliar cobertura del espacio de iluminación.	N
Paso 2	#3. Calcular estadísticas de canales RGB para normalización del modelo	Mean RGB = [0.543, 0.523, 0.498], Std RGB = [0.261, 0.263, 0.273]. Media cercana a 0.5 y std ~0.27 uniforme entre canales. Valores difieren de ImageNet (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]).	La normalización es crítica para la convergencia del modelo. Si se usa transfer learning con backbone preentrenado en ImageNet se deben usar las estadísticas de ImageNet; si se entrena from scratch, usar las estadísticas propias del dataset.	Almacenar estos valores mean/std para el pipeline de normalización de datos.	S le (r p n e Ir e c r d
Paso	#4. Detectar imágenes duplicadas	743 imágenes duplicadas (7.2% del dataset). Algunos grupos con hasta 6 copias	Riesgo grave de data leakage: si duplicados quedan repartidos entre train y validation/test, las	Crítico: Eliminar duplicados conservando una sola copia	

2	dentro del dataset usando hash MD5	idénticas (e.g., img_005027 con 6 réplicas). Predominantemente en clases door y obstacle.	métricas estarán artificialmente infladas. Además, duplicados causan overfitting al sobrerrepresentar ciertas escenas.	por hash MD5. Deduplicar antes del split train/val/test para evitar contaminación.	N
Paso 2	#5. Verificar integridad de archivos de imagen	Todas las 10,386 imágenes son válidas, legibles y en formato RGB. Sin archivos corruptos, truncados ni en formatos inesperados (RGBA, grayscale).	No se requiere limpieza de archivos. El pipeline de carga de datos no necesita manejo especial de errores de lectura.	NA	N
Paso 2	#6. Extraer dimensiones de todas las imágenes	Resolución 100% uniforme: todas las imágenes son 640×640 px. Una única resolución en todo el dataset.	Excelente consistencia: no se requiere padding ni redimensionamiento heterogéneo. 640×640 es el input estándar de YOLO. Sin embargo, para ESP32-S3 (TinyML) se requerirá downscale significativo a 96×96 o 192×192 por limitaciones de RAM (~512 KB SRAM).	Redimensionar a resolución objetivo del modelo embebido (e.g., 192×192 para ESP32-S3) durante la preparación del dataset de entrenamiento final.	E 6 m Y T c e m (f y re m b
Paso 3	#7. Obtener categorías y conteos (distribución detallada)	Confirma distribución: obstacle (7,470), door (4,724), person (4,215), stair (2,889), dog (1,256). Las 3 clases top (obstacle, door, person) acumulan 79.8% de las instancias.	Desbalance moderado-alto. dog con solo 6.1% puede no alcanzar recall aceptable sin compensación. Para la aplicación robótica, la clase dog representa un agente biológico impredecible que requiere detección fiable para activar modos de "parada de seguridad".	Augmentation focalizada en dog (flip horizontal, color jitter, mosaic con mayor peso). Evaluar si se requiere recolección adicional de datos para dog.	U b o E u c d c ir
Paso 3	#8. Obtener Densidad de Imágenes vs. Objetos	person aparece en solo 936 imágenes pero con 4,215 instancias (4.5 obj/img). dog en 436 img (2.88 obj/img). obstacle en 3,092 img (2.42 obj/img). door en 3,698 img (1.28 obj/img). stair en 2,559 img (1.13 obj/img).	person y dog son clases "densas": pocas imágenes pero muchas instancias por imagen. Esto dificulta la detección por oclusión mutua y requiere NMS robusto. Para navegación socialmente consciente, detectar múltiples personas solapadas es crítico.	NA	A t f c d c (- U a g m a
		Clases altamente independientes. Mayor co-ocurrencia: obstacle-door (191	Las escenas son predominantemente mono-clase. El modelo aprenderá representaciones independientes por	Considerar mosaic augmentation	

Paso 3	#9. Obtener Matriz de Co-ocurrencia	obstacle-door (136 img), obstacle-person (136 img). dog es prácticamente aislado (0 con obstacle, 4 con person, 0 con door/stair). stair-door casi nunca co-ocurren (3 img).	independientes por clase más que contextos multiclase complejos. La ausencia de dog con otras clases indica que las imágenes de perros provienen de un dataset diferente al resto.	para crear escenas artificiales con múltiples clases co-ocurrentes y enriquecer el aprendizaje contextual.	N
Paso 3	#10. Calcular ratio Objetos/Imagen por categoría	person: 4.50 obj/img, dog: 2.88, obstacle: 2.42, door: 1.28, stair: 1.13. Person tiene densidad 4x mayor que stair.	Alto ratio en person confirma escenas grupales (socially-aware navigation). Para el robot, esto implica que en presencia de una persona, probablemente hay más; el planificador de rutas debe considerar proxémica dinámica de grupo.	NA	V t n s p ~ si E n v 10 u
Paso 4	#11. Extraer geometría de bounding boxes	20,554 anotaciones analizadas. stair: área media mayor (188,734 px²). door (89,272), dog (64,625), obstacle (52,907), person (31,314). Aspect ratio muy variable: dog (mean=4.54, std=11.48), obstacle (mean=2.07, std=9.33) muestran altísima dispersión.	Gran diversidad de formas y tamaños. stair tiende a ocupar gran parte de la imagen. La alta varianza en aspect ratio de dog y obstacle indica formas heterogéneas (muebles, macetas, cables vs. mesas, sillas), lo que dificulta detección con anchors fijos.	NA	U a (Y u u o K h g fa a F
Paso 4	#12. Visualizar la Distribución de Tamaños COCO	Predominancia de objetos Large (>96%): door 97.4%, stair 96.9%, dog 89.6%, obstacle 79.8%, person 66.4%. Person tiene mayor proporción de Medium (30.3%) y Small (3.3%). Objetos Small son marginales en todas las clases.	Dataset dominado por objetos grandes, coherente con cámaras indoor a corta distancia. Para ESP32-S3 a 192x192, los objetos grandes seguirán siendo detectables. Los Small objects de person (3.3%) se perderán casi completamente al hacer downscale.	NA	P d (L (s si e a T a p R re 1! p p n
Paso 4	#13. Visualizar el Aspect Ratio	Distribución amplia con outliers extremos (ratios >10). door y person tienden a ser verticales (mediana <1). dog tiene la dispersión más extrema (IQR de 0.5 a 4.8). obstacle es relativamente cuadrado (mediana ~1). stair centrado	La diversidad de aspect ratios confirma la necesidad de anchors variados o modelo anchor-free. Para TinyML, la cuantización debe preservar la capacidad de detectar formas verticales (puertas, personas) y horizontales	NA	A a ra si e a a C e e > c ~

		~17. Star centrado en ~1.2.	horizontales (escaleras, obstáculos bajos).		e a
Paso 4	#14. Visualizar el Heatmap Espacial	Concentración de centroides en la zona central de la imagen, con patrón de "cruz" en los ejes vertical y horizontal centrales. Distribución relativamente simétrica. Zonas periféricas con menor densidad de anotaciones.	La concentración central es esperable (los fotografías centran objetos). No hay sesgo fuerte hacia esquinas específicas, lo que reduce riesgo de sesgo posicional. Para la cámara del robot, los obstáculos frontales estarán típicamente centrados.	NA	N
Paso 4	#15. Extraer dimensiones normalizadas de todos los bboxes	20,554 bounding boxes extraídos con ancho y alto normalizados en rango [0,1]. Paso intermedio para la optimización de anchors.	Normalización permite comparar dimensiones independientemente de la resolución, facilitando el cálculo de anchors transferibles entre resoluciones (640 para entrenamiento → 192 para inferencia en ESP32-S3).	NA	N
Paso 4	#16. Calcular y visualizar anchors óptimos usando K-Means (10 Clusters)	10 anchors calculados sobre 20,554 bboxes. Rango desde pequeños (A1: 0.119x0.142) hasta grandes (A10: 0.913x0.926). Buena cobertura del espacio de dimensiones con distribución uniforme de clusters.	Los anchors personalizados mejoran significativamente el IoU medio respecto a anchors genéricos al capturar la distribución específica de este dataset. Relevante solo para modelos anchor-based (YOLOv5, v7).	NA	S a ir a Y (a e ir re c d ta d
Paso 4	#17a. Exportar configuración YAML con Anchors optimizados	Anchors exportados en 3 escalas: P3/8 (pequeños): [76x91, 110x226, 233x108]; P4/16 (medianos): [118x392, 496x100, 145x553]; P5/32 (grandes): [294x311, 328x539, 525x362, 584x592].	Archivo YAML listo para configuración YOLO. Los anchors cubren desde ~12% hasta ~92% del tamaño de imagen 640x640. Para TinyML, deberán reescalarsse proporcionalmente a la resolución de inferencia.	NA	C a c e Y m b p si re d
Paso 5	#17b. Visualizar Histograma de Densidad de objetos por imagen	Distribución right-skewed con promedio de 2.0 obj/img. Mayoría de imágenes tiene 1-3 objetos. Outliers extremos: 1 imagen con 96 objetos. Cola larga con imágenes de >20	Escenas generalmente simples (1-2 objetos), favorable para ESP32-S3 con memoria limitada. Sin embargo, outliers con >20 objetos sugieren posible ruido de anotación o escenas atípicas (e.g.,	Revisar y potencialmente re-anotar imágenes con >30 objetos (posible ruido de anotación). Verificar la imagen con 96	E m a p e A y m d d

		objetos (escala log).	fiestas con muchas personas). El máximo de 96 es sospechoso.	objetos.	d
Paso 5	#18. Visualizar Histograma de Oclusión (IoU) entre Objetos	Mayoría de pares con IoU bajo (<0.1), distribución exponencialmente decreciente. Pocos casos con IoU >0.5 (alta oclusión). Pequeña fracción con IoU ≈ 1.0 (posibles anotaciones duplicadas o completamente superpuestas).	Baja oclusión general facilita la detección y reduce la complejidad del NMS. Los casos IoU ≈ 1.0 son potenciales errores de anotación (dos boxes idénticas sobre el mismo objeto). Para ESP32-S3, NMS simple será suficiente en la mayoría de escenas.	Investigar y eliminar anotaciones con IoU >0.9 entre sí (posibles duplicados de anotación).	C th ~ T ir si (e b g
Paso 5	#19. Resumen numérico de Densidad	10,386 imágenes analizadas. 35 imágenes vacías (background, 0.34%). Promedio: 1.98 obj/img. Máximo: 96 obj/img.	Las 35 imágenes vacías (sin anotaciones) son negative samples valiosos: reducen falsos positivos enseñando al modelo a no detectar cuando no hay nada. El promedio bajo (~2 obj/img) es favorable para hardware limitado.	Conservar las 35 imágenes vacías como background samples. Revisar la imagen con 96 objetos para verificar calidad.	Ir b (v e p p F n rc n o ir
Paso 6	#20, #21, #22. Visualizar 3 muestras aleatorias de imágenes con anotaciones (Sanity Check)	Las 3 muestras (24 imágenes totales) muestran anotaciones visualmente coherentes. Bounding boxes bien ajustados. Diversidad de escenarios: salas, pasillos, escaleras, puertas de diferentes estilos, obstáculos variados (muebles, objetos). Se identifican bboxes con fondos limpios (imágenes de catálogo de muebles vs. fotos reales de interiores).	Calidad general de anotación aceptable. La diversidad de escenarios favorece generalización. Sin embargo, se observa que parte del dataset proviene de imágenes de catálogo/e-commerce (fondo blanco), lo cual difiere del contexto real de la cámara del robot.	NA	C a c b c re d fo re d d
Paso 6	#23. Detectar anomalías en anotaciones	36 cajas minúsculas (<15×15px, área <225px²): predominan en bordes de imagen (coordenadas 0 o 639) con ancho/alto de 1-3px. Clases afectadas: obstacle (11), person (22), dog (1), door (2). 366 cajas gigantes (> 650px de ancho).	Cajas tiny son artefactos de anotación en bordes (objetos recortados fuera del frame). Para ESP32-S3 a 192×192, estos objetos de 1-3px serían completamente invisibles (~0.3px tras downscale). Las cajas gigantes de stair son semánticamente correctas (escalera	Eliminar las 36 anotaciones minúsculas (ruido, no aportan valor). Revisar cajas gigantes de obstacle con ratio >0.98 y eliminar las que sean errores. Conservar cajas gigantes de stair (correctas)	N

		(>95% del frame): predominan en stair (~250) y obstacle (~12).	= toda la escena = peligro máximo). Las de obstacle al 100% del frame son cuestionables.	de stair (peligro estructural válido).	
Paso 6	#24. Visualizar imágenes anómalas con cajas minúsculas	Imágenes confirman que las cajas tiny son objetos parcialmente fuera del frame: personas cortadas en bordes, obstáculos en el extremo de la foto. También se observan imágenes de alta densidad (crowds de personas) donde algunas personas lejanas generan bboxes de 1-3px.	Las cajas en bordes no aportan información útil al modelo y pueden introducir ruido en la función de pérdida (el modelo intentará aprender a predecir objetos de 1px). Para detección robótica, objetos fuera del campo visual no son accionables.	Eliminar anotaciones con ancho <5px o alto <5px. Filtrar también anotaciones con área <100px² como umbral conservador.	N
Paso 6	#25. Visualizar imágenes anómalas con cajas gigantes	Las imágenes muestran escaleras que ocupan todo el frame (correcto: la escalera ES toda la escena visible). También obstáculos al ~100% del frame. Varias imágenes de escaleras son close-ups de peldaños (válidas para detección a corta distancia).	Para navegación robótica, una escalera que llena el campo visual equivale a "peligro inminente": alerta máxima al sistema de control. Estas imágenes son valiosas para entrenamiento. Los obstacles a pantalla completa son menos informativos porque no representan una escena navegable real.	Conservar cajas gigantes de stair (representan detección de peligro a corta distancia). Evaluar individualmente cajas gigantes de obstacle y eliminar las no representativas de escenarios reales de navegación.	N

🔴 Conclusión Final:

El dataset presenta una base sólida de **10,386 imágenes** a 640x640 con **5 clases** relevantes para navegación robótica indoor (obstacle, door, person, stair, dog), sin problemas de integridad de archivos y con resolución uniforme. Sin embargo, se identifican **4 acciones críticas de preprocesado** antes de entrenar:

1. **Deduplicación (Prioridad CRÍTICA):** Eliminar 743 imágenes duplicadas (~7.2%) ANTES del split train/val/test para evitar data leakage.
2. **Limpieza de anomalías:** Eliminar 36 anotaciones minúsculas (<5px) y revisar 366 cajas gigantes (conservar stair, filtrar obstacle sospechosos).
3. **Augmentation selectiva para desbalance:** Reforzar clases minoritarias (dog: 6.1%, stair: 14.1%) con augmentation focalizada.
4. **Investigar anotaciones con IoU ≈ 1.0:** Posibles duplicados de anotación a depurar.

Para el **entrenamiento orientado a TinyML/ESP32-S3**, las principales consideraciones son:

- Usar **Focal Loss** y class weights para compensar desbalance.
- Establecer **max_detections ≤ 20** para acotar uso de memoria en inferencia.
- Priorizar **cabeza P5 (objetos grandes)** y simplificar/eliminar P3 (small objects) en la arquitectura.
- Incluir **imágenes background** (vacías) para reducir falsos positivos en

navegación real.

- Entrenar con **progressive resizing** (640→320→192) para robustez a baja resolución.

Preprocesado del Dataset

Esta sección del notebook se centra en la preparación de los datos para el entrenamiento del modelo de detección de objetos.

- **Paso 1:** Data Augmentation
- **Paso 2:** Split del Dataset (train/valid/test)
- **Paso 3:** Normalización de Imágenes (mean/std)
- **Paso 4:** Guardar el Dataset Preprocesado en Formato YOLO

Paso 1: Data Augmentation (Análisis y Planificación)

Una vez identificadas las clases minoritarias en las fases anteriores, es momento de planificar la estrategia de **Data Augmentation** para balancear el dataset.

Objetivos:

1. **Identificar necesidades:** Calcular déficit de instancias por clase respecto a un objetivo.
2. **Planificar estrategia:** Determinar cuántas copias aumentadas generar por imagen candidata.
3. **Visualizar impacto:** Proyectar distribución ANTES vs DESPUÉS del augmentation.
4. **Ejecutar pipeline:** (Opcional) Integrar transformaciones de albumentations para generar dataset balanceado.

Estrategias de Transformación:

- **Mild (Suave):** HorizontalFlip, RandomBrightnessContrast, GaussNoise, GaussianBlur - para clases con déficit < 100 instancias.
- **Aggressive (Agresiva):** Affine (rotación, escala, traslación), ColorJitter, RandomGamma, MotionBlur - para clases altamente minoritarias.

Nota: El pipeline completo de augmentation se ejecuta mediante el script standalone `01_ING_DATOS/Datasets/Augmentation_dataset.py` que genera un nuevo dataset sin modificar el original.

```
In [30]: # --- ANÁLISIS DE NECESIDADES DE AUGMENTATION ---
# Definir objetivo de instancias por clase (ajustar según criterio)
# TARGET_INSTANCES = 400 # Valor objetivo para balanceo

# Analizar qué clases son minoritarias
# df_augmentation_analysis = analyze_augmentation_needs(coco, target_i
#                                                                    output_dir=out
#                                                                    filename='25_a
```

```
In [31]: # --- PLANIFICACIÓN DE ESTRATEGIA ---
# Calcular cuántas copias aumentadas se necesitan por imagen
# df_augmentation_plan = compute_augmentation_strategy(df_augmentation
#                                                                    output_dir=outp
#                                                                    filename='26_a
```

```
In [32]: # --- VISUALIZACIÓN DEL IMPACTO ---
# Comparar distribución ANTES vs DESPUÉS (proyectado)
# if len(df_augmentation_plan) > 0:
#     visualize_augmentation_impact(df_augmentation_analysis, df_augmen
#                                     output_dir=output_dir, filename='27
# else:
#     print("\n✅ No se requiere visualización: dataset ya está balanceado")
```

Ejecución del Pipeline de Augmentation

Para ejecutar el pipeline completo de data augmentation con albumentations:

```
cd /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets
python Augmentation_dataset.py
```

El script realiza:

1. Copia completa del dataset original a `dataset_maestro_aug/`
2. Identifica imágenes candidatas que contienen classes minoritarias
3. Aplica transformaciones mild/aggressive según el déficit
4. Genera imágenes aumentadas con sus anotaciones YOLO
5. Exporta:
 - `augmentation_log.csv` : Trazabilidad de imágenes generadas
 - `class_distribution.png` : Gráfico ANTES/DESPUÉS
 - `data.yaml` : Configuración actualizada

Ventajas:

- ✅ No modifica el dataset original
- ✅ Preserva formato YOLO (imágenes + labels .txt)
- ✅ Transformaciones bbox-aware (no corta objetos)
- ✅ Log completo de trazabilidad

Paso 2: Split de Dataset

- **Comparación Multi-Split:**
 - **Objetivo:** Verificar que train/valid/test tengan distribuciones de clases similares (test Chi-cuadrado).

```
In [33]: # --- COMPARACIÓN DE DISTRIBUCIÓN ENTRE SPLITS ---
# NOTA: No aplica para el dataset unificado (no hay splits train/valid)
# Esta comparación se realizará después de dividir el dataset en split
# print("🚫 Comparación multi-split omitida: el dataset unificado no")
```

```
In [34]: # Test Chi-cuadrado para verificar homogeneidad estadística entre splits
# NOTA: No aplica para el dataset unificado (requiere múltiples splits)
# Se ejecutará después de dividir el dataset en splits para entrenar
# print("🚫 Test Chi-cuadrado omitido: requiere múltiples splits.")
```

```
In [35]: # Analizar distribución de imágenes y anotaciones por split
# df_split_dist = analyze_split_distribution(splits, output_dir=output_dir)
```

Paso 3: Guardar Dataset Preprocesado en Formato YOLO