

Preprocesado del Dataset

Esta sección del notebook se centra en la preparación de los datos para el entrenamiento del modelo de detección de objetos.

- **Paso 1:** Mitigación de Falsos Positivos mediante Inyección de imágenes de fondo sin objetos (espacios libres) en el dataset.
- **Paso 2:** Redimensionamiento uniforme: Las 65 resoluciones diferentes del dataset se deben normalizar a 640x640 (letterbox para preservar aspect ratio) para crear batches de entrenamiento uniformes.
- **Paso 3:** Split del Dataset (train/valid/test) estratificadas.
- **Paso 4:** Analizar la distribución de clases del set train para detectar posibles desbalances y aplicar técnicas de augmentación si es necesario.
- **Paso 5:** Guardar el Dataset Preprocesado en Formato YOLO, COCO y TFRecord para su uso en diferentes frameworks de entrenamiento.

```
In [1]: # Auto-reload: recarga módulos automáticamente al detectar cambios en
%load_ext autoreload
%autoreload 2

# Librerías
import os
import sys
import json
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
import cv2
import random
import hashlib
import yaml
from pycocotools.coco import COCO
from sklearn.cluster import KMeans
from pathlib import Path
import zipfile

# Rutas base
base_dir = "/Users/admin/Documents/TFM_UNIR/01_ING_DATOS"

# Añadir path de utilidades
src_path = os.path.join(base_dir, "src")
```

```

if src_path not in sys.path:
    sys.path.insert(0, src_path)
from utils_edu import *
from utils_preprocessing import *

# Directorio de salida para guardar reportes
output_dir = os.path.join(base_dir, "Reports", "Process_Dataset_IODC_o

```

```

In [2]: # Descomprimir el Dataset
dataset_path = os.path.join(base_dir, "Datasets", "dataset_IODC_origin

# Descomprimir el Dataset
unzip_datasets(source_dir=dataset_path)

```

Se encontraron 1 archivos .zip

Descomprimiendo: IODC-background-yolo26.zip
Destino: IODC-background-yolo26/
✓ Completado - 2501 archivos extraídos

=====

Proceso completado

```

In [3]: # Ruta del dataset descomprimido (con data.yaml + train/images + train
dataset_path_unzip = os.path.join(dataset_path, "IODC-background-yolo2

# Procesar dataset YOLO: normalizar clases, serializar imágenes, reest
stats = process_yolo_dataset(
    dataset_path=dataset_path_unzip,
    output_dir=dataset_path,
    class_overrides={"escalator": "stair"},
    output_dir_reports=output_dir
)

```

🔧 Procesamiento de Dataset YOLO

=====

📁 Origen: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/IODC-background-yolo26
📁 Destino: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3

📁 Fase 1: Descubrimiento de clases...

📋 Mapeo global unificado:

- 0: dog
- 1: door
- 2: obstacle
- 3: person
- 4: stair

Total de clases únicas: 5

**Traducción de clases:**

0:'dog' → 0:'dog' (sin cambio)
 1:'door' → 1:'door' (sin cambio)
 2:'obstacle' → 2:'obstacle' (sin cambio)
 3:'person' → 3:'person' (sin cambio)
 4:'stair' → 4:'stair' (sin cambio)

**Fase 2: Creando estructura de destino...**

/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IOD
 C_original_3/data/images



/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IOD
 C_original_3/data/labels

**Fase 3: Procesando imágenes y labels...**

Splits encontrados: ['train']



train: 1249 imágenes procesadas



Total de imágenes procesadas: 1249

**Fase 4: Generando data.yaml unificado...**

/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IOD
 C_original_3/data.yaml


Clases (5): ['dog', 'door', 'obstacle', 'person', 'stair']

**Fase 5: Generando log de trazabilidad...**

/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IOD
 C_original_3/process_log.csv (1249 registros)

**Fase 6: Distribución de clases...**

Clase	ID	Instancias	Porcentaje
dog	0	485	16.1%
door	1	541	18.0%
obstacle	2	882	29.3%
person	3	592	19.7%
stair	4	509	16.9%
TOTAL		3,009	100.0%



 Gráfica guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_OIDC_original_v2/class_distribution.png

=====

 PROCESAMIENTO COMPLETADO

=====

 Directorio: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3

 Imágenes: 1,249

 Clases: 5 → ['dog', 'door', 'obstacle', 'person', 'stair']

 BB totales: 3,009

Paso 1: Mitigación de Falsos Positivos

El EDA determinó que la totalidad de las imágenes originales contenían al menos un objeto anotado, factor que incrementa el riesgo de "alucinación" de objetos en espacios vacíos dentro de un entorno doméstico. En consecuencia, la literatura reciente demuestra que integrar entre el 10% y el 15% de muestras de fondo (De 112 a 168 imágenes, en el caso actual), permiten al modelo reconocer el ruido visual de interiores como una clase de relleno, optimizando la precisión al reducir la tasa de falsos positivos (Lee et al., 2025; Glez-Peña et al., 2023;). Más aún en dispositivos de borde (Edge AI) como el ESP32-S3, donde se manejan resoluciones bajas y los píxeles de fondo pueden biselarse y parecerse a los objetos de interés.

- **Composición y Criterios Técnicos de las Muestras de Fondo:** Para asegurar la eficacia de esta inyección, las imágenes son capturadas en el entorno desde la perspectiva egocéntrica del robot, centrándose en texturas y geometrías permanentes del contexto real. Las tomas incluyen planos de tierra despejados (Ej. baldosas), intersecciones entre paredes y suelos para evitar confusiones con bordes de muebles, y espacios de transición vacíos. Se mantienen los mismos criterios técnicos generales del dataset original.
- **Metodología de Obtención y Validación de Integridad:** La generación de este subconjunto se realizó mediante dos vías complementarias: la captura real, utilizando la interfaz de control del robot para obtener ráfagas en zonas vacías, y la generación sintética mediante modelos de inteligencia artificial ajustados a una resolución de 640x640.

Finalmente, se garantizó que estas imágenes se estuviesen estrictamente "limpias" de etiquetas. La presencia de elementos no catalogados —como la sección de un mueble no etiquetada— enviaría señales contradictorias al sistema, indicando erróneamente que un objeto de interés debe ser interpretado como fondo. Como resultado final se obtuvo:

- **Dataset_Background_1:** 87 Fotos tomadas desde la ESP32-S3 + CAM OV5640 a resolución FRAMSIZE_QVGA 800x600 pixeles [iluminación variable].
- **Dataset_Background_2:** 38 imágenes sintéticas a resoluciones variables [escenarios creados totalmente desde cero con instrucciones basadas en los criterios técnicos objetivo].

```
In [4]: # Variables necesarias
coco, img_dir = load_yolo_as_coco(dataset_path)
img_ids = coco.getImgIds()
target_cat_ids = coco.getCatIds()
id_to_name = {cat['id']: cat['name'] for cat in coco.loadCats(target_cat_ids)}
# Asignar colores automáticamente a cada clase
_color_pool = [
    (255, 0, 0),      # Rojo
    (0, 255, 0),      # Verde
    (0, 0, 255),      # Azul
    (255, 255, 0),    # Cyan/Amarillo
    (255, 0, 255),    # Magenta
    (0, 255, 255),    # Amarillo (BGR)
]
class_colors = {name: _color_pool[i % len(_color_pool)] for i, name in id_to_name.items()}
density_counts, ious = calculate_density_and_iou(coco, target_cat_ids)
images_bg = [coco.loadImgs(img_id)[0]['file_name'] for img_id, count in density_counts.items()]
```

loading annotations into memory...

Done (t=0.00s)

creating index...

index created!

✅ Dataset YOLO cargado como COCO:

📁 Imágenes: 1249

📝 Anotaciones: 3009

📁 Categorías: ['dog', 'door', 'obstacle', 'person', 'stair']

Procesando imágenes para calcular IoU y Densidad...

In [8]: `print(f" Se tienen {density_counts.count(0)} imágenes sin objetos o ba`

Se tienen 125 imágenes sin objetos o background, lo que representa el 10.01% del total de imágenes.

```
In [12]: # Obtener IDs de imágenes de fondo (sin objetos)
bg_img_ids = [img_id for img_id, count in zip(img_ids, density_counts)

# Seleccionar 8 aleatorios
sample_ids = random.sample(bg_img_ids, min(8, len(bg_img_ids)))

# Visualizar usando visualize_sample
base_img_dir = os.path.join(dataset_path, "data", "images")

# Llamar a visualize_sample pasando la lista de IDs seleccionados
visualize_sample(
    coco=coco,
    target_cat_ids=target_cat_ids,
    id_to_name=id_to_name,
    class_colors=class_colors,
    img_dir=base_img_dir,
    num_samples=len(sample_ids),
    img_ids=sample_ids,
    filename='02_visual_sample_background_images.png',
    title="Muestras de Imágenes de Fondo (Background)"
)
```

Muestras de Imágenes de Fondo (Background)



Paso 2: Redimensionamiento uniforme

Las 65 resoluciones diferentes del dataset se deben normalizar a 640x640 (letterbox para preservar aspect ratio) para crear batches de entrenamiento uniformes.

```
In [15]: # Extraer dimensiones de todas las imágenes
splits = {'all': coco}
df_dimensions = get_image_dimensions(splits)
display(df_dimensions.head())

# Normalización dimensional a 640x640 usando Letterbox (con padding gr
input_coco_json = os.path.join(dataset_path, "_annotations.coco.json")
input_images_dir = img_dir
letterbox_output_dir = os.path.join(dataset_path, "letterbox_640")

summary_letterbox = letterbox_coco_dataset_offline(
    coco_json_path=input_coco_json,
    images_dir=input_images_dir,
    output_dir=letterbox_output_dir,
    output_json_name="_annotations.letterbox.coco.json",
    target_size=(640, 640),
    padding_color=(114, 114, 114),
)

display(pd.DataFrame([summary_letterbox]))

# Validación rápida: debe haber una sola resolución (640x640)
output_json_path = str(summary_letterbox["output_json_path"])
dims_check = summarize_image_dimensions_from_coco(output_json_path)
print("\nValidación de resoluciones:")
print(dims_check)
```

	image_id	width	height	split
0	1	512	379	all
1	2	508	371	all
2	3	508	375	all
3	4	1024	765	all
4	5	1024	765	all

 Directorio creado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Data sets/dataset_IODC_original_3/letterbox_640

 Directorio creado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Data sets/dataset_IODC_original_3/letterbox_640/data/images

 Iniciando normalización Letterbox COCO...

 JSON entrada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datase ts/dataset_IODC_original_3/_annotations.coco.json

 Imágenes entrada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/D ataset/dataset_IODC_original_3/data/images

 Salida: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dat aset_IODC_original_3/letterbox_640

 Progreso: 200/1249 imágenes revisadas

 Progreso: 400/1249 imágenes revisadas

 Progreso: 600/1249 imágenes revisadas

 Progreso: 800/1249 imágenes revisadas

 Progreso: 1000/1249 imágenes revisadas

 Progreso: 1200/1249 imágenes revisadas

 Letterbox offline completado

 Imágenes procesadas: 1249

 Imágenes faltantes: 0

 Imágenes no legibles: 0

 Anotaciones entrada: 3009

 Anotaciones salida: 3009

 Anotaciones descartadas: 0

 JSON salida: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Dataset s/dataset_IODC_original_3/letterbox_640/_annotations.letterbox.coco.js on

output_json_path

0 /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/D... /Users/admin/Documents/TFM

Validación de resoluciones:

{'num_images': 1249, 'num_unique_resolutions': 1}

```
In [24]: # Visualizar sample de 8 imágenes del dataset Letterbox
letterbox_json_path = os.path.join(letterbox_output_dir, "_annotations
letterbox_img_dir = os.path.join(letterbox_output_dir, "data", "images

if not os.path.exists(letterbox_json_path):
    raise FileNotFoundError(f"No se encontró el JSON letterbox: {lette
if not os.path.exists(letterbox_img_dir):
    raise FileNotFoundError(f"No se encontró el directorio de imágenes

# Cargar COCO transformado
coco_letterbox = COCO(letterbox_json_path)
target_cat_ids_letterbox = coco_letterbox.getCatIds()
id_to_name_letterbox = {
    cat['id']: cat['name']
    for cat in coco_letterbox.loadCats(target_cat_ids_letterbox)
```

```

}

# Reutilizar paleta que ya existe
class_colors_letterbox = class_colors

# Seleccionar 8 imágenes aleatorias
img_ids_letterbox = coco_letterbox.getImgIds()
sample_ids_letterbox = random.sample(
    img_ids_letterbox,
    min(8, len(img_ids_letterbox))
)

# Visualizar con utilidad existente
visualize_sample(
    coco=coco_letterbox,
    target_cat_ids=target_cat_ids_letterbox,
    id_to_name=id_to_name_letterbox,
    class_colors=class_colors_letterbox,
    img_dir=letterbox_img_dir,
    num_samples=len(sample_ids_letterbox),
    img_ids=sample_ids_letterbox,
    output_dir=output_dir,
    filename='03_visual_sample_letterbox_images.png',
    title="Muestras de Imágenes Post Resized Letterbox 640x640"
)

print(f"✅ Se visualizaron {len(sample_ids_letterbox)} imágenes desde:

```


loading annotations into memory...

Done (t=0.01s)

creating index...

index created!

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/03_visual_sample_letterbox_images.png



✓ Se visualizaron 8 imágenes desde: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/letterbox_640/data/images

Paso 3: Split del Dataset (train/valid/test) estratificadas.

Se realiza la división del dataset en conjuntos de entrenamiento, validación y prueba, asegurando que cada conjunto mantenga una distribución representativa de las clases presentes en el dataset original así como de aquellas imágenes que no tienen etiquetas (imagenes background o negativas).

Esto se logra mediante técnicas de muestreo estratificado, que garantizan que la proporción de cada clase se mantenga constante en cada subconjunto.

- **Train Set:** 70% de las imágenes, utilizado para entrenar el modelo.
- **Validation Set:** 15% de las imágenes, utilizado para ajustar hiperparámetros y prevenir el sobreajuste.
- **Test Set:** 15% de las imágenes, utilizado para evaluar el rendimiento final del modelo.

```
In [29]: # División del Dataset en Train/Val/Test (70/15/15) con estratificación
from utils_preprocessing import CocoSplitConfig, split_coco_dataset_stratified

split_source_json = os.path.join(letterbox_output_dir, "_annotations.json")
split_source_images = os.path.join(letterbox_output_dir, "data", "images")
split_output_dir = os.path.join(dataset_path, "dataset_split")

split_config = CocoSplitConfig(
    train_ratio=0.70,
    valid_ratio=0.15,
    test_ratio=0.15,
    seed=42,
    copy_images=True,
)

split_summary = dict(
    split_coco_dataset_stratified(
        coco_json_path=split_source_json,
        images_dir=split_source_images,
        output_dir=split_output_dir,
        config=split_config,
    )
)

# Resumen general
display(pd.DataFrame([
```

```

    {
        "output_dir": split_summary.get("output_dir"),
        "source_num_images": split_summary.get("source_num_images"),
        "source_num_annotations": split_summary.get("source_num_annota
        "assigned_total_images": split_summary.get("assigned_total_ima
        "assigned_unique_images": split_summary.get("assigned_unique_i
    }
]))

# Resumen por split
split_rows = []
split_map = dict(split_summary.get("splits", {}))
for split_name in ["train", "valid", "test"]:
    info = dict(split_map.get(split_name, {}))
    copy_stats = dict(info.get("copy_stats", {}))
    split_rows.append({
        "split": split_name,
        "num_images": info.get("num_images"),
        "num_annotations": info.get("num_annotations"),
        "num_background_images": info.get("num_background_images"),
        "json_path": info.get("json_path"),
        "images_dir": info.get("images_dir"),
        "copied_images": copy_stats.get("copied"),
        "missing_images": copy_stats.get("missing"),
        "copy_errors": copy_stats.get("errors"),
    })

display(pd.DataFrame(split_rows))

```

 Iniciando split estratificado COCO...

 JSON entrada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/letterbox_640/_annotations.letterbox.coco.json

 Imágenes fuente: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/letterbox_640/data/images

 Salida: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split

 Objetivo imágenes: {'train': 874, 'valid': 188, 'test': 187}

 Split COCO completado

TRAIN: 874 imgs | 1671 anns | 87 background

VALID: 188 imgs | 762 anns | 19 background

TEST: 187 imgs | 576 anns | 19 background

	output_dir	source_num_images	source
0	/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/D...	1249	

	split	num_images	num_annotations	num_background_images
0	train	874	1671	87 /Users/admin/D
1	valid	188	762	19 /Users/admin/D
2	test	187	576	19 /Users/admin/D

```
In [35]: # Analizar distribución de clases por split (incluye background) y exportar
from utils_preprocessing import analyze_split_class_distribution

split_train_json = os.path.join(split_output_dir, "train", "_annotations.json")
split_valid_json = os.path.join(split_output_dir, "valid", "_annotations.json")
split_test_json = os.path.join(split_output_dir, "test", "_annotations.json")

split_json_paths = {
    "train": split_train_json,
    "valid": split_valid_json,
    "test": split_test_json,
}

df_split_classes = analyze_split_class_distribution(
    split_json_paths=split_json_paths,
    class_names=["dog", "door", "person", "obstacle", "stair", "background"],
    palette="magma",
    figsize=(10, 5),
    title="Distribución de Clases por Split",
    output_dir=output_dir,
    filename="04_split_class_distribution",
    show_plot=True,
)

display(df_split_classes)
```



```

loading annotations into memory...
Done (t=0.00s)
creating index...
index created!
loading annotations into memory...
Done (t=0.00s)
creating index...
index created!
loading annotations into memory...
Done (t=0.00s)
creating index...
index created!

```


 Distribución de clases por split:


split	dog	door	person	obstacle	stair	backgr ound
	total_annotations		total_images			
train	277	245	309	545	295	87
valid	150	160	182	164	106	19
test	58	136	101	173	108	19

 Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_OIDC_original_v2/04_split_class_distribution.csv

 Figura porcentual guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_OIDC_original_v2/04_split_class_distribution_pct.png

 Figura absoluta guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_OIDC_original_v2/04_split_class_distribution_abs.png





	split	dog	door	person	obstacle	stair	background	total_annotations	total
0	train	277	245	309	545	295	87	1671	
1	valid	150	160	182	164	106	19	762	
2	test	58	136	101	173	108	19	576	

Paso 4: Análisis de la Distribución de Clases del Set Train

Analizar la distribución de clases del set train para detectar posibles desbalances y aplicar técnicas de augmentación si es necesario.

```
In [36]: # Analizar la distribución de clases del set train para evaluar desbal

# Filtrar solo Train
df_train = df_split_classes[df_split_classes['split'] == 'train'].copy
if df_train.empty:
    raise ValueError("No se encontró la fila del split 'train' en df_s

# plot_category_distribution() espera columnas: Category, Count
exclude_cols = {'split', 'total_annotations', 'total_images', 'backgro
class_cols = [c for c in df_train.columns if c not in exclude_cols]

df_train_counts = (
    df_train[class_cols]
    .iloc[0]
    .rename_axis('Category')
    .reset_index(name='Count')
```

```

        .sort_values('Count', ascending=False)
        .reset_index(drop=True)
    )


display(df_train_counts)

plot_category_distribution(
    df_counts=df_train_counts,
    scale_type='linear',
    palette='magma',
    output_dir=output_dir,
    filename='05_class_distribution_train',
    title='Distribución de Clases de Train Set (Escala Lineal)'
)

```

	Category	Count
0	obstacle	545
1	person	309
2	stair	295
3	dog	277
4	door	245

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/05_class_distribution_train.png



--- Tabla de Distribución ---

Category	Count
obstacle	545
person	309
stair	295
dog	277
door	245

 Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/05_class_distribution_train.csv

```
In [37]: # Obtener la densidad Imágenes vs Objetos por clase para el split TRAIN

# Cargar explícitamente el JSON de train (evita mezclar con el dataset)
if not os.path.exists(split_train_json):
    raise FileNotFoundError(f"No se encontró el JSON de train: {split_train_json}")

coco_train = COCO(split_train_json)
cat_ids_train = coco_train.getCatIds()

# calculate_image_object_density(coco, cat_ids) -> (df_density, active_cat_ids)
df_density, active_cat_ids = calculate_image_object_density(coco_train, cat_ids_train)

display(df_density)

# plot_image_object_density(df_density, palette, figsize, output_dir,
#                             df_density=df_density,
#                             palette='magma',
#                             figsize=(12, 6),
#                             output_dir=output_dir,
#                             filename='06_image_object_density_train',
#                             title='Densidad de Imágenes vs. Objetos por Clase (TRAIN)'
# )
```

loading annotations into memory...

Done (t=0.01s)

creating index...

index created!

	Category	Images	Objects
0	dog	243	277
1	door	197	245
2	obstacle	386	545
3	person	283	309
4	stair	285	295

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/06_image_object_density_train.png




```
In [38]: # Calcular ratio Objetos/Imagen por categoría
df_ratio = calculate_and_plot_density_ratio(
    df_density,
    palette='magma',
    output_dir=output_dir,
    filename='07_density_ratio',
    title='Ratio Objetos/Imagen por Clase (TRAIN)'
)
```

--- Ratio de Densidad (Promedio de objetos por imagen donde aparece la clase) ---

Category	Images	Objects	Ratio
obstacle	386	545	1.4119
door	197	245	1.2437
dog	243	277	1.1399
person	283	309	1.0919
stair	285	295	1.0351

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_OIDC_original_v2/07_density_ratio.png


 Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_OIDC_original_v2/07_density_ratio.csv



```
In [39]: # Obtener Matriz de Co-ocurrencia
co_occurrence_matrix, cat_labels = calculate_cooccurrence_matrix(coco,
plot_cooccurrence_matrix(
    co_occurrence_matrix,
    cat_labels,
    cmap='YlGnBu',
    output_dir=output_dir,
    filename='08_cooccurrence_matrix',
    title='Matriz de Co-ocurrencia de Clases (TRAIN)'
)
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/08_cooccurrence_matrix.png

Matriz guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/08_cooccurrence_matrix.csv



Paso 5: Data Augmentation

Con base en los gráficos previos del análisis del Train Set (874 imágenes y 1,671 anotaciones), donde se observa que la clase `obstacle` (545) duplica en frecuencia a `door` (245) y supera significativamente a `dog` (277), `stair` (295) y `person` (309), procedemos a estructurar el plan final de aumentación. Se plantea el siguiente plan de aumentación para mitigar este desbalance:

Para un robot LCMR con hardware limitado (ESP32-S3), el balanceo no es solo una cuestión estadística, sino de seguridad operativa:

- **Navegación Semántica y Crítica:** Las clases `door` (transición) y `stair` (límite/riesgo) son estructuralmente más importantes que un `obstacle` genérico. Un sesgo hacia `obstacle` podría causar que el robot intente atravesar una "puerta" o ignore el peligro de una "escalera" al clasificarlos erróneamente como objetos estáticos simples.

- **Seguridad Biológica:** Las clases `person` y `dog` requieren un Recall extremadamente alto. Dado que el modelo se cuantizará a INT8, el margen de error se reduce; un dataset equilibrado asegura que los pesos de la red no se saturen con características de muebles, permitiendo una discriminación fina de agentes móviles.
- **Compensación de Ratios:** El ratio de objetos por imagen es bajo (1.04 a 1.24 para las clases débiles). Esto significa que el modelo ve pocos ejemplos por captura; el balanceo offline compensará esta baja densidad de información por frame.

1. Matriz de Aumentación Offline (Fase de Balanceo)

Esta fase se ejecuta antes del entrenamiento para igualar el volumen de las clases al nivel de `obstacle`.

Clase	Target de Aumento	Técnicas Específicas	Lógica de Programación y Configuración
dog	+97% (de 277 a 545)	Horizontal Flip + Gaussian Noise	Aplicar flip y añadir ruido ($\sigma = 0.02$) para emular sensor OV5640 en noche.
door	+122% (de 245 a 545)	Horizontal Flip + Perspective Warp	Invertir x y aplicar skew leve ($\pm 5\%$) para simular aproximación diagonal del robot.
stair	+85% (de 295 a 545)	Horizontal Flip + Crop/Zoom	Invertir x y hacer zoom ($1.1x$) para simular que el robot está más cerca del límite estructural.
person	+76% (de 309 a 545)	Horizontal Flip + Blur/Sharpen	Invertir x y aplicar desenfoque leve para simular movimiento relativo persona-robot.

2. Matriz de Aumentación Online (Fase de Generalización)

Estas transformaciones ocurren en cada epoch para que el modelo no memorice el dataset balanceado, se detallan acá para tenerlas en cuenta pero se desarrollarán en la sección de entrenamiento del proyecto.

Técnica	Configuración Sugerida	Qué Asegurar / Lógica
		Asegurar: Obliga a

Mosaic (4-img)	Probabilidad: 1.0 (100%)	detectar objetos en miniatura. Vital para la pérdida de resolución a 192×192 .
HSV-Hue	$h = 0.015, s = 0.7, v = 0.4$	Lógica: Variar tono, saturación y valor. Asegurar: No cambiar el color natural (ej. que un perro no sea azul).
Degrees (Rot)	$\pm 10.0^\circ$	Lógica: Rotaciones aleatorias. Asegurar: El robot opera en suelos; rotaciones mayores son irreales.
Multiscale	Rango: 320 a 640 px	Lógica: Cambiar resolución cada 10 batches. Asegurar: Robustez ante múltiplos inferiores de resoluciones de 640px

3. Salvaguardas y control de errores

Para garantizar que la implementación sea exitosa, se debe evitar estos fallos comunes:

Posible Fallo / Categoría	Descripción del Error	Acción o Restricción Crítica
Inversión de Coordenadas	El BBox queda en el lado opuesto al objeto real si no	Lógica: La nueva coordenada x_{center} debe ser $1.0 - x_{old_center}$.

(Flip)	se recalcula el centro.	
Prohibición de Vertical Flip	Invertir el eje <i>Y</i> destruye la percepción del plano de tierra del robot.	Restricción: Bajo ninguna circunstancia invertir el eje <i>Y</i> ; los obstáculos deben permanecer en el suelo.
Ajuste "Tight" (BBox)	En <i>Crop</i> o <i>Perspective</i> , el cuadro se aleja de los bordes del objeto.	Asegurar: El BBox debe seguir tocando los bordes (anotación modal) para no perder precisión en el ESP32-S3.
Cascada en Co-ocurrencia	Aumentar una clase (ej. <i>dog</i>) afecta involuntariamente a otra presente (ej. <i>obstacle</i>).	Script: Implementar un contador en tiempo real que detenga el aumento al alcanzar el target (545) de la clase objetivo.

```
In [42]: # Ejecución de la Aumentación Offline (solo TRAIN)
dataset_split_dir = os.path.join(
    base_dir,
    "Datasets",
    "dataset_IODC_original_3",
    "dataset_split",
)

offline_aug_output_dir = os.path.join(
    dataset_split_dir,
    "train_augmented_offline_v1",
)

# Matriz de políticas offline definida en la celda 26
offline_policies = build_default_offline_balance_policies(target_count

# Control de cascada por co-ocurrencia (tope con tolerancia)
cascade_cfg = CascadeControlConfig(
    enabled=True,
    collateral_tolerance_ratio=0.03,
    target_overshoot_tolerance=2,
    enforce_for_all_classes=True,
)

run_cfg = OfflineAugRunConfig(
    seed=42,
    min_bbox_area=4.0,
    min_visibility=0.20,
    max_generated_images=20000,
    output_json_name="_annotations.coco.json",
    output_images_subdir="images",
    verbose=True,
)

summary_offline_aug = augment_dataset_split_train_offline(
    dataset_split_dir=dataset_split_dir,
```

```

        output_dir=offline_aug_output_dir,
        policies=offline_policies,
        cascade_cfg=cascade_cfg,
        run_cfg=run_cfg,
    )

    print("\n📌 Resumen general")
    print(f"Output dir: {summary_offline_aug['output_dir']}")
    print(f"JSON salida: {summary_offline_aug['output_json_path']}")
    print(f"Imágenes generadas: {summary_offline_aug['generated_images']}")

    print("\n📊 Reporte de targets")
    display(pd.DataFrame(summary_offline_aug["target_report"]))

    if summary_offline_aug.get("rejection_reasons"):
        print("\n⚠️ Rechazos por reglas de control")
        display(
            pd.DataFrame(
                [
                    {"reason": k, "count": v}
                    for k, v in summary_offline_aug["rejection_reasons"].items()
                ]
            ).sort_values("count", ascending=False)
        )

```

 Directorio creado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1

 Directorio creado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1/images

 Iniciando augmentación offline balanceada (TRAIN)

 JSON train: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train/_annotations.coco.json

 Imágenes train: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train/images

 Output: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1

 Targets:

- dog: 277 -> 545
- door: 245 -> 545
- stair: 295 -> 545
- person: 309 -> 545

 Augmentación offline completada

dog: 277 -> 545 (target=545, OK)

door: 245 -> 545 (target=545, OK)

stair: 295 -> 548 (target=545, OK)

person: 309 -> 545 (target=545, OK)

 Imágenes generadas: 596

 JSON salida: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1/_annotations.coco.json

 Resumen general

Output dir: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1

JSON salida: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1/_annotations.coco.json

Imágenes generadas: 596

 Reporte de targets

	class_id	class_name	before	after	delta	target	target_hit
0	0	dog	277	545	268	545	True
1	1	door	245	545	300	545	True
2	4	stair	295	548	253	545	True
3	3	person	309	545	236	545	True

 Rechazos por reglas de control

	reason	count
0	collateral_cap_exceeded:2	166

```

In [45]: # Setup de comparación TRAIN before vs after (offline augmentation)
train_before_json = os.path.join(dataset_split_dir, "train", "_annotat
train_before_images_dir = os.path.join(dataset_split_dir, "train", "im

train_after_json = os.path.join(offline_aug_output_dir, "_annotations.
train_after_images_dir = os.path.join(offline_aug_output_dir, "images"

compare_output_dir = os.path.join(
    output_dir,
    "09_before_after_train_offline_v1",
)
ensure_dir(compare_output_dir)

print("📁 Rutas de trabajo")
print(f"- TRAIN before json: {train_before_json}")
print(f"- TRAIN before images: {train_before_images_dir}")
print(f"- TRAIN after json: {train_after_json}")
print(f"- TRAIN after images: {train_after_images_dir}")
print(f"- Output comparación: {compare_output_dir}")

compare_ctx = load_train_before_after_coco(
    before_json_path=train_before_json,
    after_json_path=train_after_json,
)

print("\n📋 Resumen before/after")
display(compare_ctx["summary_df"])

# Integridad estructural before y after
integrity_before = validate_coco_annotation_integrity(
    coco_json_path=train_before_json,
    images_dir=train_before_images_dir,
    min_bbox_area=4.0,
    check_image_readability=True,
)

integrity_after = validate_coco_annotation_integrity(
    coco_json_path=train_after_json,
    images_dir=train_after_images_dir,
    min_bbox_area=4.0,
    check_image_readability=True,
)

print("\n✅ Integridad BEFORE")
print(f"Status: {integrity_before['status']} | errores críticos: {inte
display(integrity_before["report_df"])

print("\n✅ Integridad AFTER")
print(f"Status: {integrity_after['status']} | errores críticos: {integ
display(integrity_after["report_df"])

```



Rutas de trabajo

- TRAIN before json: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train/_annotations.coco.json
- TRAIN before images: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train/images
- TRAIN after json: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1/_annotations.coco.json
- TRAIN after images: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1/images
- Output comparación: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_IODC_original_v2/09_before_after_train_offline_v1

loading annotations into memory...
 Done (t=0.01s)
 creating index...
 index created!
 loading annotations into memory...
 Done (t=0.01s)
 creating index...
 index created!



Resumen before/after

	version	num_images	num_annotations	num_categories
0	before	874	1671	5
1	after	1470	2744	5



Integridad BEFORE

Status: PASS | errores críticos: 0 | total: 0

	check	count
0	duplicate_image_ids	0
1	duplicate_annotation_ids	0
2	missing_image_files	0
3	unreadable_images	0
4	invalid_annotation_image_ref	0
5	invalid_annotation_category_ref	0
6	invalid_bbox_format	0
7	invalid_bbox_size	0
8	bbox_out_of_bounds	0
9	bbox_area_mismatch	0



Integridad AFTER

Status: PASS | errores críticos: 0 | total: 0

	check	count
0	duplicate_image_ids	0
1	duplicate_annotation_ids	0
2	missing_image_files	0
3	unreadable_images	0
4	invalid_annotation_image_ref	0
5	invalid_annotation_category_ref	0
6	invalid_bbox_format	0
7	invalid_bbox_size	0
8	bbox_out_of_bounds	0
9	bbox_area_mismatch	0

```
In [46]: # Comparación before vs after con las 4 métricas base (celdas 20-23) +
if "compare_ctx" not in globals():
    raise RuntimeError("Ejecuta primero la celda de setup before/after")

results_ref = compare_train_before_after_reference_metrics(
    coco_before=compare_ctx["coco_before"],
    coco_after=compare_ctx["coco_after"],
    output_dir=compare_output_dir,
    prefix="09_before_after_train_ref",
    palette="magma",
)

print("\n📊 Delta distribución de clases (before -> after)")
display(results_ref["class_compare"].sort_values("Delta", ascending=False))

print("\n📊 Delta densidad imágenes/objetos")
display(results_ref["density_compare"].sort_values("Delta_objects", ascending=False))

print("\n📊 Delta ratio objetos/imagen")
display(results_ref["ratio_compare"].sort_values("Delta_ratio", ascending=False))

print("\n📊 Delta matriz de co-ocurrencia (after - before)")
display(results_ref["cooccurrence_delta"])

# Heatmap de delta de co-ocurrencia para inspección del efecto cascada
plt.figure(figsize=(9, 7))
sns.heatmap(
    results_ref["cooccurrence_delta"],
    annot=True,
    fmt=".0f",
    cmap="coolwarm",
    center=0,
```

```

)
plt.title("Delta Co-ocurrencia (After - Before)")
plt.xticks(rotation=45)
plt.yticks(rotation=0)
plt.tight_layout()
plt.show()

# Métricas adicionales (beyond celdas 20-23)
results_ext = compare_train_before_after_additional_metrics(
    coco_before=compare_ctx["coco_before"],
    coco_after=compare_ctx["coco_after"],
    output_dir=compare_output_dir,
    prefix="09_before_after_train_ext",
)

print("\n🧩 Resumen de métricas adicionales")
display(results_ext["summary_df"])

print("\n📝 Nota metodológica")
print(
    "Además de distribución/densidad/ratio/co-ocurrencia, se compararon  


    geometría de bboxes, mapas espaciales y complejidad de escena (de
)

# Identificar imágenes nuevas generadas por la augmentación
augmented_ids_info = get_augmented_image_ids(
    before_coco=compare_ctx["coco_before"],
    after_coco=compare_ctx["coco_after"],
    filename_token="__aug_",
)

print("\n🆕 Imágenes detectadas como nuevas")
print(f"- Por file_name diff: {len(augmented_ids_info['new_by_filename'])}")
print(f"- Por image_id diff: {len(augmented_ids_info['new_by_id'])}")
print(f"- Por token '__aug_': {len(augmented_ids_info['token_ids'])}")
print(f"- Total combinado: {len(augmented_ids_info['augmented_ids'])}")

```

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_01_class_distribution_before.png




--- Tabla de Distribución ---

Category	Count
obstacle	545
person	309
stair	295
dog	277
door	245

Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_01_class_distribution_before.csv

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_02_class_distribution_after.png



--- Tabla de Distribución ---

Category	Count
obstacle	561
stair	548
dog	545
door	545
person	545

 Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_02_class_distribution_after.csv

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_03_density_before.png





Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_04_density_after.png




--- Ratio de Densidad (Promedio de objetos por imagen donde aparece la clase) ---

Category	Images	Objects	Ratio
obstacle	386	545	1.4119
door	197	245	1.2437
dog	243	277	1.1399
person	283	309	1.0919
stair	285	295	1.0351

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_05_ratio_before.png

Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_05_ratio_before.csv



--- Ratio de Densidad (Promedio de objetos por imagen donde aparece la clase) ---

Category	Images	Objects	Ratio
obstacle	402	561	1.3955
door	446	545	1.222
dog	472	545	1.1547
person	512	545	1.0645
stair	530	548	1.034

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_06_ratio_after.png

 Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_06_ratio_after.csv




 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_07_cooccurrence_before.png

 Matriz guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_07_cooccurrence_before.csv




 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_08_cooccurrence_after.png

 Matriz guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ref_08_cooccurrence_after.csv



 Delta distribución de clases (before -> after)

	Category	Count_before	Count_after	Delta
1	door	245	545	300
0	dog	277	545	268
4	stair	295	548	253
3	person	309	545	236
2	obstacle	545	561	16

 Delta densidad imágenes/objetos


	Category	Images_before	Objects_before	Images_after	Objects_after	Delta_
1	door	197	245	446	545	
0	dog	243	277	472	545	
4	stair	285	295	530	548	
3	person	283	309	512	545	
2	obstacle	386	545	402	561	

 Delta ratio objetos/imagen

	Category	Ratio_before	Ratio_after	Delta_ratio
0	dog	1.1399	1.1547	0.0148
4	stair	1.0351	1.0340	-0.0011
2	obstacle	1.4119	1.3955	-0.0164
1	door	1.2437	1.2220	-0.0217
3	person	1.0919	1.0645	-0.0274

 Delta matriz de co-ocurrencia (after – before)

	dog	door	obstacle	person	stair
dog	229.0	53.0	11.0	29.0	53.0
door	53.0	249.0	5.0	78.0	82.0
obstacle	11.0	5.0	16.0	0.0	0.0
person	29.0	78.0	0.0	229.0	102.0
stair	53.0	82.0	0.0	102.0	245.0



Geometría de Bounding Boxes extraída: 1671 anotaciones

Category	Count	Area_mean	Area_median	Ratio_mean	Ratio_std
dog	277	50702.4	39210.3	1.1	0.48
door	245	75205.1	73244.2	0.47	0.21
obstacle	545	55773.4	47837.1	0.75	0.38
person	309	67607.5	55410.4	0.52	0.24
stair	295	64020.4	57315.6	1.28	0.59

Geometría guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_01_geo_before.csv

Resumen guardado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_01_geo_before_summary.csv

Geometría de Bounding Boxes extraída: 2744 anotaciones


Category	Count	Area_mean	Area_median	Ratio_mean	Ratio_std
dog	545	52706.8	40734.7	1.13	0.5
door	545	79889.9	77075.2	0.49	0.24
obstacle	561	55808.8	47798.7	0.75	0.38
person	545	67699.2	56426.7	0.55	0.25
stair	548	69268	61605.7	1.27	0.59

Geometría guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_02_geo_after.csv

Resumen guardado: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_02_geo_after_summary.csv

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_03_size_before.png

<Figure size 1000x600 with 0 Axes>




--- Porcentaje de Tamaños por Clase ---

Category	Large (>96²)	Medium
dog	91.7	8.3
door	100	0
obstacle	98.35	1.65
person	99.68	0.32
stair	99.66	0.34

Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_03_size_before_percentages.csv

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_04_size_after.png

<Figure size 1000x600 with 0 Axes>



--- Porcentaje de Tamaños por Clase ---

Category	Large (>96²)	Medium
dog	91.93	8.07
door	100	0
obstacle	98.22	1.78
person	99.63	0.37
stair	99.82	0.18


Tabla guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_04_size_after_percentages.csv

/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/src/utils_eda.py:1018: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df_geo, x='Category', y='Ratio', palette=palette)
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_05_aspect_before.png



/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/src/utils_eda.py:1018: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df_geo, x='Category', y='Ratio', palette=palette)
```

Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_06_aspect_after.png




Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_07_spatial_before.png





Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_ before_after_train_ext_08_spatial_after.png



Procesando imágenes para calcular IoU y Densidad...

Procesando imágenes para calcular IoU y Densidad...

 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_09_density_hist_before.png




Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_10_density_hist_after.png




Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Reports/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_11_iou_hist_before.png





 Figura guardada: /Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Report s/Process_Dataset_0IDC_original_v2/09_before_after_train_offline_v1/09_before_after_train_ext_12_iou_hist_after.png



 Resumen de métricas adicionales

	metric	before	after	delta
0	mean_objects_per_image	1.911899	1.866667	-0.045233
1	median_objects_per_image	2.000000	2.000000	0.000000
2	mean_iou_neighbors	0.047228	0.048148	0.000920

 Nota metodológica

Además de distribución/densidad/ratio/co-ocurrencia, se compararon: geometría de bboxes, mapas espaciales y complejidad de escena (densidad+IoU).

 Imágenes detectadas como nuevas

- Por file_name diff: 596
- Por image_id diff: 596
- Por token '__aug_': 596
- Total combinado: 596

```
In [49]: # Visual QA de imágenes nuevas de augmentación usando visualize_sample
if "compare_ctx" not in globals() or "augmented_ids_info" not in globa
    raise RuntimeError("Ejecuta primero las celdas de setup y comparac

if not augmented_ids_info["augmented_ids"]:
    print("⚠ No se detectaron imágenes nuevas para visualización.")
else:
    review_samples = sample_augmented_image_ids_for_review(
        after_coco=compare_ctx["coco_after"],
        augmented_img_ids=augmented_ids_info["augmented_ids"],
        per_class=3,
        random_k=12,
        seed=42,
    )

    print("\n📝 Muestreo para revisión visual")
    print(f"- Estratificadas por clase: {len(review_samples['stratified_ids'])}")
    print(f"- Aleatorias globales: {len(review_samples['random_ids'])}")
    print(f"- Total final (únicas): {len(review_samples['final_ids'])}")

    target_cat_ids_after = compare_ctx["cat_ids_after"]
    id_to_name_after = compare_ctx["id_to_name_after"]

    color_pool = [
        (255, 0, 0),
        (0, 255, 0),
        (0, 0, 255),
        (255, 255, 0),
        (255, 0, 255),
        (0, 255, 255),
        (128, 0, 255),
        (255, 128, 0),
    ]

    class_names_after = [id_to_name_after[cid] for cid in target_cat_ids_after]
    class_colors_after = {
        cls_name: color_pool[i % len(color_pool)]
        for i, cls_name in enumerate(class_names_after)
    }

    visualize_sample(
        coco=compare_ctx["coco_after"],
        target_cat_ids=target_cat_ids_after,
```

```

    id_to_name=id_to_name_after,
    class_colors=class_colors_after,
    img_dir=train_after_images_dir,
    img_ids=review_samples["final_ids"][:8],
    filename="09_before_after_visual_augmented_samples",
    title="Muestras de imágenes aumentadas (validación estructural
)

# Vista rápida solo aleatoria para control adicional
if review_samples["random_ids"]:
    visualize_sample(
        coco=compare_ctx["coco_after"],
        target_cat_ids=target_cat_ids_after,
        id_to_name=id_to_name_after,
        class_colors=class_colors_after,
        img_dir=train_after_images_dir,
        img_ids=review_samples["random_ids"][:8],
        filename="09_before_after_visual_augmented_random_only",
        title="Muestras aleatorias de imágenes aumentadas"
    )

```

✓ Muestreo para revisión visual

- Estratificadas por clase: 15
- Aleatorias globales: 12
- Total final (únicas): 27

Muestras de imágenes aumentadas (validación estructural y semántica)





Resultados de la Aumentación Offline del Set Train

1. Hallazgos cuantitativos principales

- La fase de aumentación offline cumplió su objetivo de balanceo por clase, elevando las clases minoritarias al entorno del umbral de referencia (545 instancias): `dog` = 545, `door` = 545, `person` = 545 y `stair` = 548.
- La clase `obstacle`, inicialmente mayoritaria, aumentó de 545 a 561 (+16), lo que evidencia un crecimiento colateral acotado.
- El set de entrenamiento se expandió de forma consistente de **874 a 1470 imágenes** y de **1671 a 2744 anotaciones**, manteniendo invariantes las **5 categorías** originales.
- La comparativa de densidad imagen-objeto y de ratio objetos/imagen sugiere una mejora de cobertura en clases débiles sin alterar de forma drástica la estructura estadística de escena.

2. Evidencia del control de cascada por co-ocurrencia

- La matriz de co-ocurrencia before/after muestra el incremento esperado en combinaciones entre clases por efecto de replicación aumentada.
- No obstante, el crecimiento en pares asociados a `obstacle` se mantiene bajo en términos relativos, lo cual es consistente con la lógica de freno por cascada implementada.
- En consecuencia, se observa **balanceo efectivo** sin inflado descontrolado de la clase originalmente dominante.

3. Validación estructural del dataset (COCO)

- La auditoría de integridad before/after reportó **0 errores críticos**.
- No se detectaron IDs duplicados, referencias inválidas (`image_id` / `category_id`), bboxes fuera de rango, inconsistencias de área ni archivos de imagen faltantes/no legibles.
- Estos resultados respaldan que la pipeline preservó correctamente la consistencia formal del dataset.

4. Estabilidad geométrica y complejidad de escena

- Las métricas geométricas complementarias (área, mediana, aspect ratio y tamaños COCO) conservaron patrones globales similares entre before y after.
- Los mapas espaciales de localización de objetos mantienen una distribución coherente con el comportamiento original del dataset.
- En complejidad de escena y oclusión, la mediana de objetos por imagen se mantuvo estable y la variación media de IoU vecinas fue mínima, sin señales de degradación estructural relevante.

5. Validación visual y semántica de muestras aumentadas

- La inspección visual estratificada y aleatoria de imágenes nuevas mostró alineación adecuada entre objeto y bbox en los casos revisados.
- Las transformaciones aplicadas (flip horizontal + transformación específica por clase) preservan la coherencia semántica general de las anotaciones.

6. Implicaciones para entrenamiento y riesgos residuales

- El nuevo train set queda mejor condicionado para entrenamiento en escenarios Edge AI, al reducir el sesgo por desbalance interclase y aumentar la cobertura efectiva de clases críticas.
- Como mejora menor no bloqueante, queda pendiente ajustar el warning de `seaborn` asociado al uso de `palette` sin `hue` en algunos boxplots para asegurar compatibilidad futura.

Conclusión

En conjunto, la estrategia de aumentación offline implementada **mejora significativamente el balance interclase sin comprometer la integridad estructural del dataset ni la coherencia geométrica/semántica de las anotaciones**, por lo que el set Train resultante se considera apto para la siguiente fase de entrenamiento del detector.

Paso 6: Guardar el Dataset Preprocesado en Formato YOLO, COCO y TFRecord

Para su uso en diferentes frameworks de entrenamiento, se guardará el dataset preprocesado en los siguientes formatos:

- **YOLO:** Se guardará en formato YOLO, que es ampliamente utilizado para tareas de detección de objetos. Este formato consiste en archivos de texto donde cada línea representa una anotación con la clase y las coordenadas normalizadas del bounding box.
- **COCO:** Se guardará en formato COCO, que es un estándar para datasets de detección de objetos. Este formato utiliza un archivo JSON que contiene información sobre las imágenes, las anotaciones y las categorías.
- **TFRecord:** Se guardará en formato TFRecord, que es un formato optimizado para TensorFlow. Este formato permite almacenar grandes cantidades de datos de manera eficiente y es especialmente útil para el entrenamiento de modelos en TensorFlow.

```
In [1]: # Paso 6 - Exportar dataset final a COCO / YOLO / TFRecord
# Recarga explícita del módulo para usar siempre la última versión.

import os
import sys
import importlib

if "base_dir" not in globals():
    base_dir = os.path.abspath(os.path.join(os.getcwd(), ".."))

src_path = os.path.join(base_dir, "src")
if src_path not in sys.path:
    sys.path.insert(0, src_path)

import utils_preprocessing as up
up = importlib.reload(up)

source_split_root = os.path.join(
    base_dir,
    "Datasets",
    "dataset_IODC_original_3",
    "dataset_split",
)

output_root = os.path.abspath(
    os.path.join(base_dir, "..", "02_ING_MODELOS", "datasets", "IODC")
)

paths_cfg = up.DatasetExportPathsConfig(
```

```
train_split_dir=os.path.join(source_split_root, "train_augmented_o
valid_split_dir=os.path.join(source_split_root, "valid"),
test_split_dir=os.path.join(source_split_root, "test"),
output_root_dir=output_root,
include_empty_yolo_labels=True,
tfrecord_shards=1,
)

mapping_cfg = up.DatasetClassMappingConfig(
    yolo_zero_based=True,
    tfrecord_one_based=True,
)

export_summary = up.export_dataset_all_formats(
    paths_cfg=paths_cfg,
    mapping_cfg=mapping_cfg,
    export_coco=True,
    export_yolo=True,
    export_tfrecord=True,
)

up.print_dataset_export_summary(export_summary)
export_summary
```


 Directorio creado: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/tfrecord/train

 Directorio creado: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/tfrecord/valid

 Directorio creado: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/tfrecord/test

 Exportación de dataset completada

 Output root: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC

 Mapping de clases:

```

COCO[0]=dog -> YOLO[0], TF[1]
COCO[1]=door -> YOLO[1], TF[2]
COCO[2]=obstacle -> YOLO[2], TF[3]
COCO[3]=person -> YOLO[3], TF[4]
COCO[4]=stair -> YOLO[4], TF[5]

```

 Formato COCO: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco

```

- train: images=1470, annotations=2744
- valid: images=188, annotations=762
- test: images=187, annotations=576

```

 Formato YOLO: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/yolo

```

- train: images=1470, labels=1470, objects=2744
- valid: images=188, labels=188, objects=762
- test: images=187, labels=187, objects=576

```

 Formato TFRECORD: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/tfrecord

```

- train: examples=1470, shards=1
- valid: examples=188, shards=1
- test: examples=187, shards=1

```

 YOLO data.yaml: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/yolo/data.yaml

 TF label_map: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/tfrecord/label_map.pbtxt

 TF metadata: /Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/tfrecord/metadata.json

```

Out[1]: {'output_root_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC',
        'source_splits': {'train': '/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/train_augmented_offline_v1',
                           'valid': '/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/valid',
                           'test': '/Users/admin/Documents/TFM_UNIR/01_ING_DATOS/Datasets/dataset_IODC_original_3/dataset_split/test'},
        'class_mapping': {'categories': [{'coco_id': 0,
                                           'name': 'dog'},

```

```

        'yolo_id': 0,
        'tfrecord_id': 1},
    {'coco_id': 1, 'name': 'door', 'yolo_id': 1, 'tfrecord_id': 2},
    {'coco_id': 2, 'name': 'obstacle', 'yolo_id': 2, 'tfrecord_id':
3},
    {'coco_id': 3, 'name': 'person', 'yolo_id': 3, 'tfrecord_id': 4},
    {'coco_id': 4, 'name': 'stair', 'yolo_id': 4, 'tfrecord_id': 5}}},
    'formats': {'coco': {'root_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco'},
    'splits': {'train': {'json_path': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco/train/_annotations.coco.json',
        'images_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco/train/images',
        'num_images': 1470,
        'num_annotations': 2744,
        'copy_stats': {'copied': 1470, 'missing': 0, 'errors': 0}},
    'valid': {'json_path': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco/valid/_annotations.coco.json',
        'images_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco/valid/images',
        'num_images': 188,
        'num_annotations': 762,
        'copy_stats': {'copied': 188, 'missing': 0, 'errors': 0}},
    'test': {'json_path': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco/test/_annotations.coco.json',
        'images_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/coco/test/images',
        'num_images': 187,
        'num_annotations': 576,
        'copy_stats': {'copied': 187, 'missing': 0, 'errors': 0}}}},
    'yolo': {'root_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/yolo',
    'splits': {'train': {'images_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/yolo/train/images',
        'labels_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/yolo/train/labels',
        'num_images': 1470,
        'num_annotations': 2744,
        'labels_written': 1470,
        'objects_written': 2744,
        'objects_dropped': 0,
        'copy_stats': {'copied': 1470, 'missing': 0, 'errors': 0}},
    'valid': {'images_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/yolo/valid/images',
        'labels_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datasets/IODC/yolo/valid/labels',
        'num_images': 188,
        'num_annotations': 762,
        'labels_written': 188,
        'objects_written': 762,
        'objects_dropped': 0,
        'copy_stats': {'copied': 188, 'missing': 0, 'errors': 0}},

```

```

    'test': {'images_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_M0
DELOS/datasets/IODC/yolo/test/images',
    'labels_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/da
taset/IODC/yolo/test/labels',
    'num_images': 187,
    'num_annotations': 576,
    'labels_written': 187,
    'objects_written': 576,
    'objects_dropped': 0,
    'copy_stats': {'copied': 187, 'missing': 0, 'errors': 0}},
    'data_yaml': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/datas
ets/IODC/yolo/data.yaml'},
    'tfrecord': {'root_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_M0
DELOS/datasets/IODC/tfrecord',
    'splits': {'train': {'split_dir': '/Users/admin/Documents/TFM_UNI
R/02_ING_MODELOS/datasets/IODC/tfrecord/train',
    'shards': 1,
    'tfrecord_files': ['/Users/admin/Documents/TFM_UNIR/02_ING_MODEL
OS/datasets/IODC/tfrecord/train/data-00000-of-00001.tfrecord'],
    'num_images': 1470,
    'num_annotations': 2744,
    'examples_written': 1470,
    'examples_skipped': 0,
    'images_missing': 0},
    'valid': {'split_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_M0
DELOS/datasets/IODC/tfrecord/valid',
    'shards': 1,
    'tfrecord_files': ['/Users/admin/Documents/TFM_UNIR/02_ING_MODEL
OS/datasets/IODC/tfrecord/valid/data-00000-of-00001.tfrecord'],
    'num_images': 188,
    'num_annotations': 762,
    'examples_written': 188,
    'examples_skipped': 0,
    'images_missing': 0},
    'test': {'split_dir': '/Users/admin/Documents/TFM_UNIR/02_ING_MOD
ELOS/datasets/IODC/tfrecord/test',
    'shards': 1,
    'tfrecord_files': ['/Users/admin/Documents/TFM_UNIR/02_ING_MODEL
OS/datasets/IODC/tfrecord/test/data-00000-of-00001.tfrecord'],
    'num_images': 187,
    'num_annotations': 576,
    'examples_written': 187,
    'examples_skipped': 0,
    'images_missing': 0}},
    'label_map_path': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/
datasets/IODC/tfrecord/label_map.pbtxt',
    'metadata_path': '/Users/admin/Documents/TFM_UNIR/02_ING_MODELOS/d
ataset/IODC/tfrecord/metadata.json'}}}

```

In [6]: *# Paso 7 - Validación post-export automática (sanity checks + muestreo*

```
import importlib
```

```
import utils_preprocessing as up

up = importlib.reload(up)

if "export_summary" not in globals():
    raise RuntimeError("Primero ejecuta la celda de exportación (Paso

validation_report = up.validate_exported_dataset_postcheck(
    export_summary=export_summary,
    samples_per_split=1, # comparación cruzada: 1 imagen train + 1 va
    seed=None,           # aleatorio en cada ejecución; usa un int pa
    show_visual_samples=True,
    save_visual_samples=False, # cambia a True si quieres guardar imá
)


# validation_report
```

Validación visual cruzada por formato (mismas imágenes train/valid/test)**Formato: COCO**


train | id=1198 | img_001198.jpg | anns=0



valid | id=547 | img_000547.jpg | anns=5




test | id=291 | img_000291.jpg | anns=3

**Formato: YOLO**


train | id=1198 | img_001198.jpg | anns=0




valid | id=547 | img_000547.jpg | anns=5




test | id=291 | img_000291.jpg | anns=3

**Formato: TFRECORD**


train | id=1198 | img_001198.jpg | anns=0



valid | id=547 | img_000547.jpg | anns=5



test | id=291 | img_000291.jpg | anns=3



Validación post-export

Estado global: PASS

- COCO: PASS

- YOLO: PASS

- TFRECORD: PASS



Sin inconsistencias críticas en los checks ejecutados